
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Центр дополнительного, дополнительного профессионального и онлайн-образования "Пуск"
Центр дополнительного, дополнительного профессионального и онлайн-образования "Пуск"

Направление подготовки / специальность: 03.04.01 Прикладные математика и физика


Направленность (профиль) подготовки: Прикладной анализ данных в медицинской сфере

СТРАТИФИКАЦИЯ РИСКОВ ОПЕРАТИВНЫХ ВМЕШАТЕЛЬСТВ У КАРДИОХИРУРГИЧЕСКИХ ПАЦИЕНТОВ

(магистерская диссертация)

Студент:

Вискер Ярослав Юрьевич



(подпись студента)

Научный руководитель:

Мусаева Татьяна Сергеевна,
канд. мед. наук



(подпись научного руководителя)

Консультант (при наличии):

(подпись консультанта)

Москва 2026

1. Аннотация

Целью работы является Разработка модели прогнозирования неблагоприятных событий у пациентов, перенесших кардиохирургическое вмешательство с использованием методов машинного обучения на основе клинико-лабораторных и инструментальных данных.

Для достижения поставленной цели решены следующие задачи: реализована предобработка клинико-анамнестических данных; построены, оптимизированы и сопоставлены шесть прогнозных моделей (от линейных до градиентного бустинга и ядерных методов); осуществлен сравнительный анализ их устойчивости к переобучению; рассчитана метрика важности признаков.

Полученные результаты: Определен оптимальный алгоритм для клинического внедрения — Random Forest, продемонстрировавший высокую точность ранжирования на независимом тесте ($\text{ROC-AUC} = 0.8494$) при высокой стабильности архитектуры. Выявлены четыре наиболее значимых факторов риска, аккумулирующих около 55% предсказательной силы: «Объем операции» (17.311%), «Класс стенокардии» (13.862%), «Функциональный класс NYHA» (12.905%), «Легочная гипертензия» (10.570%).

На основании работы рекомендовано: в качестве ядра систем поддержки принятия врачебных решений для прецизионной оценки госпитальной летальности рекомендуется использовать ПМ IV (Random Forest). Для задач первичного экспресс-мониторинга и выделения максимального пула пациентов высокого риска рекомендуется интеграция алгоритма ПМ I (Logistic Regression).

СОДЕРЖАНИЕ

1. Аннотация.....	1
2. Введение	4
3. Обозначения и сокращения.....	8
4. Теоретический анализ.	9
5. Материалы и методы	16
5.1 Клиническая характеристика.....	16
5.2. Характеристика набора данных и предобработка	20
5.2.1. Формирование признакового пространства.....	21
5.2.2. Очистка данных и нормализация	21
5.2.3. Формирование порядковых клинических переменных и категориальная трансформация.....	22
5.3. Стратегия разбиения данных и чистота эксперимента	28
5.4. Решение проблемы дисбаланса классов	28
5.5. Алгоритмы машинного обучения.....	29
5.6. Оптимизация гиперпараметров и кросс-валидация	30
5.7. Метрики качества и интерпретация моделей.....	33
6. Результаты.....	35
6.1. Архитектурное проектирование и программная реализация мультимодельного комплекса стратификации рисков	35
6.2. Анализ результатов подбора гиперпараметров и интерпретация оптимальных конфигураций моделей.....	38
6.3. Оценка качества моделей и методика адаптивного выбора порогов классификации	41
6.4. Сравнительный анализ эффективности прогностических моделей на независимой тестовой выборке	42
6.5. Анализ устойчивости разработанных моделей и оценка выраженности эффекта переобучения	46
6.6. Сравнительный анализ значимости признаков.....	49
7. Выводы	57
8. Перспективы и рекомендации	58
9. Заключение	61
Список литературы	64

Приложение	70
------------------	----

2. Введение

Актуальность темы. Кардиохирургия представляет собой одну из самых высокотехнологичных и динамично развивающихся областей современной медицины, требующую большого объема знаний и прецизионных хирургических навыков. В последние годы отмечается быстрое совершенствование оперативных техник, методик послеоперационного выхаживания и расширение показаний к хирургическому лечению. Кардиохирурги все чаще сталкиваются с исходно тяжелыми соматическими больными, обремененными большим количеством сопутствующих патологий. Сегодня успешно оперируются пациенты, которые еще десятилетие назад признавались неоперабельными.

В этой связи перед мультидисциплинарной командой специалистов («heart team») встает важная и сложная этико-медицинская задача: точно провести границу между ситуацией, когда агрессивное вмешательство принесет пациенту пользу, и ситуацией, когда операция нанесет непоправимый урон, необратимо снизит качество жизни или приведет к летальному исходу. Хорошим подспорьем для клиницистов при принятии решений в таких пограничных сценариях (например, при выборе между хирургической коррекцией и изолированной медикаментозной терапией) служат математические прогностические модели и шкалы рисков.

За последние тридцать лет в мировой практике было создано порядка 30 подобных систем (наиболее известные — американская STS и европейская EuroSCORE II), основанных на вычислительном статистическом анализе множественных переменных методами классической регрессии. Однако данные шкалы, разработанные на зарубежных когортах, демонстрируют ограниченную полезность при переносе в российскую клиническую практику. Это обусловлено географическими, экономическими, климатическими различиями, а также несовпадением возрастных профилей и

ангиографических характеристик поражения сосудов у разных этногеографических групп. На сегодняшний день в России отсутствуют валидированные отечественные системы стратификации рисков, что порождает острую потребность в их создании и последующем компаративном анализе с зарубежными аналогами.

Новым витком эволюции в этой области стало применение методов искусственного интеллекта (ИИ) и машинного обучения (МО). Алгоритмы МО способны эффективно аппроксимировать нелинейные паттерны и скрытые эффекты, превосходя традиционные логистические модели в прогнозировании специфических осложнений. Тем не менее в мировой литературе ведется дискуссия: ряд исследователей указывают на существование «эффекта потолка» для алгоритмов МО при использовании исключительно низкоразмерных дооперационных данных, отмечая сопоставимую эффективность логистической регрессии на простых линейных выборках. Другие ученые склоняются в сторону использования методов машинного обучения, так как они выдают более точные прогнозы. Необходимость разрешения этого научно-практического противоречия, а также отсутствие отечественной системы оценки рисков оперативных вмешательств на сердце определяют высокую актуальность настоящего исследования.

Объект исследования: когорта пациентов кардиохирургического профиля, перенесших оперативное вмешательство на сердце ($n = 405$).

Предмет исследования: характеристики периоперационного периода у кардиохирургических пациентов и предиктивные математические алгоритмы их анализа.

Исследовательский вопрос: какие ключевые характеристики пациента и параметры вмешательства необходимо учитывать в процессе автоматизированной поддержки принятия решений о целесообразности кардиохирургического вмешательства в условиях российской клиники?

Цель исследования: разработка, валидация и интерпретация прогностической модели неблагоприятных исходов у пациентов, перенесших кардиохирургическое вмешательство, с использованием методов машинного обучения на основе клинико-лабораторных и инструментальных данных.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Оценить непосредственные исходы операций на сердце у пациентов с различной нозологической структурой кардиохирургической патологии в исследуемой когорте.
2. Выявить и ранжировать наиболее значимые факторы риска летального исхода у пациентов после операций на сердце в госпитальном периоде.
3. Разработать комплекс моделей стратификации риска оперативного вмешательства (включая линейные методы, древесные ансамбли и машины опорных векторов) на основе алгоритмов машинного обучения.
4. Провести сравнительный анализ моделей.

Гипотеза исследования: модели машинного обучения обладают не меньшей прогностической ценностью при стратификации рисков кардиохирургических вмешательств в сравнении с традиционными методами, основанными на логической регрессии, и устойчиво демонстрируют показатель площади под ROC-кривой не менее 0.7.

Методы исследования. Проектирование и обучение пайплайнов реализовано на языке Python с использованием библиотек Scikit-learn, Pandas, а также современных фреймворков градиентного бустинга (CatBoost, LightGBM, XGBoost) и случайного леса (Random Forest). Качество моделей комплексно оценивалось по метрикам ROC-AUC, F1-score, Recall, Precision и индексу Брайера (Brier Score).

Научно-теоретическая значимость исследования:

- Математически обоснована и экспериментально подтверждена высокая эффективность применения ансамблевых нелинейных алгоритмов классификации для прогнозирования госпитальной летальности в отечественной кардиохирургической практике.
- На основе сквозного SHAP-анализа выявлены главные факторы неблагоприятного исхода.
- Был найден компромисс между переобучением модели и реалистичностью её прогнозов.

Практическая значимость исследования. Алгоритм Random Forest, показавший наилучшее качество ранжирования (ROC-AUC = 0.8494) и реалистичную калибровку (Brier Score = 0.1245), рекомендован как базовый модуль прецизионной индивидуальной оценки рисков. Логистическая регрессия с высокой чувствительностью (Recall = 0.9091) предложена в качестве надежного инструмента первичного потокового скрининга. Была определена тетрада доминантных предикторов (объем операции, класс стенокардии, ФК NYHA, ЛГ), позволяющая оптимизировать структуру электронных карт предоперационного обследования.

Апробация результатов исследования. Конференция: 68-я Всероссийская научная конференция МФТИ (30марта–4апреля). Тезис «Стратификация рисков кардиохирургических вмешательств с использованием методов машинного обучения».

3. Обозначения и сокращения

АКШ — аортокоронарное шунтирование

ВКР — выпускная квалификационная работа

ИИ — искусственный интеллект

ИК — искусственное кровообращение

ЛГ — легочная гипертензия

ЛЖ — левый желудочек (сердца)

ОПП — острое почечное повреждение

ПМ — прогностическая модель

СКФ — скорость клубочковой фильтрации

ХОБЛ — хроническая обструктивная болезнь легких

ХПН — хроническая почечная недостаточность

АНА — Американская кардиологическая ассоциация (American Heart Association)

CI/CD — непрерывная интеграция и непрерывное развертывание (Continuous Integration / Continuous Deployment)

DVC — инструмент версионирования данных (Data Version Control)

EuroSCORE — европейская система оценки риска оперативной летальности в кардиохирургии (European System for Cardiac Operative Risk Evaluation)

NYHA — Нью-Йоркская кардиологическая ассоциация (New York Heart Association)

SHAP — метод объяснения предсказаний моделей на основе аддитивных векторов Шепли (SHapley Additive exPlanations)

4. Теоретический анализ.

Кардиохирургия является высокотехнологичной областью медицины, требующая большого объема знаний и высококлассных хирургических навыков. Динамично развиваются хирургические технологии, совершенствуются методики выхаживания пациентов после операций, изменяются показания и подходы к лечению, растет сложность выполняемых операций. Наряду с этим отмечается расширение показаний к операциям на сердце. В настоящее время оперируются пациенты, которые еще 10 лет назад могли быть оценены как неоперабельные. Таким образом, кардиохирурги все чаще сталкиваются с исходно тяжелыми больными с значительным бременем сопутствующих заболеваний. В такой ситуации при принятии решений необходимо проводить границу между пациентом, которому операция действительно принесет благо, и пациентом, которому операция нанесет непоправимый урон и значительно снизит качество жизни либо приведет к летальному исходу. К сожалению, не всегда можно четко провести эту границу, но в помощь специалистам разрабатываются прогностические модели, шкалы риска, которые являются хорошим подспорьем при принятии решений в пограничных ситуациях, когда неясно, стоит ли пациента направлять на оперативное лечение, либо ограничиться только медикаментозной терапией.

За последние три десятка лет появилось большое количество прогностических моделей оценки рисков кардиохирургических вмешательств. По данным литературы их количество составляет порядка 30 [1, 2, 6]. Основная их часть разработана в странах Европы и США. Все эти системы используют различные комбинации характеристик пациента, таких как возраст, сопутствующие заболевания, сердечно-сосудистые факторы риска, экстракардиальные факторы риска и многие другие. Сегодня они представляют собой сложные системы прогнозирования, основанные на

вычислительном статистическом анализе множественных переменных с методов регрессионного анализа [3, 4]. Тем не менее, даже сегодня разные системы все еще дают разные прогнозы заболеваемости и смертности. Стоит отметить, что система стратификации риска, хорошо зарекомендовавшая себя в одной популяции, может иметь ограниченную полезность в другой крупной группе населения, имеющей расовые и этнические различия и давать некорректные прогнозы. Возможной причиной этого является различия в паттернах риска, которые влияют по-разному на пациентов, принадлежащих к разным расовым, этническим, географическим, генетическим группам. Например, японцы, жители индийского субконтинента и скандинавские популяции имеют разные возрастные профили ишемической болезни сердца и ангиографические характеристики тяжести атеросклеротического поражения коронарных артерий [6].

В России на сегодняшний день отсутствуют отечественные системы оценки риска кардиохирургических вмешательств и используются шкалы, разработанные в США и Европе. Ввиду географических, климатических, экономических различий, различающихся профилей патологии сердца, данные модели могут давать недостаточно точные прогнозы в условиях клинической практики в РФ. Таким образом, существует потребность в разработке отечественной системы стратификации рисков у пациентов, направляемых на кардиохирургические вмешательства с последующей сравнительной оценкой новой системы с уже существующими широко распространенными предиктивными моделями.

В области сердечно-сосудистой медицины искусственный интеллект (ИИ) продемонстрировал значительный потенциал, особенно в лечении заболеваний сердца и при хирургических вмешательствах. Сердечно-сосудистые заболевания (ССЗ) остаются основной причиной смертности во всем мире, что свидетельствует о необходимости применения инновационных подходов к диагностике и лечению. ИИ применяется в различных аспектах

кардиологической помощи, от стратификации риска и анализа изображений до прогнозирования результатов хирургических вмешательств. Алгоритмы на основе ИИ могут превосходить традиционные статистические модели в прогнозировании таких осложнений, как острое почечное повреждение и смертность после кардиохирургических операций. Кроме того, ИИ улучшает предоперационное планирование благодаря автоматизированному анализу эхокардиографии и компьютерной томографии КТ сердца, позволяя прецизионно оценить анатомические структуры и оптимально спланировать операцию [15].

Кардиохирургия сопряжена со значительными рисками, поэтому точная стратификация рисков имеет решающее значение для принятия решения. Традиционные инструменты, такие как EuroSCORE II и STS, широко используются, но не могут заменить клиническую оценку и мультидисциплинарные обсуждения – «heart team» [9-11]. Машинное обучение предлагает более сложную альтернативу, причем алгоритмы превосходят традиционные статистические методы в прогнозировании внутрибольничной смертности и послеоперационных осложнений [9,12,13]. Например, модели МО продемонстрировали высокую точность в определении прогностических переменных и создании диагностических функций, хотя такие вопросы, как смещение данных, калибровка и внешняя валидация, остаются сложными [10,13,14].

Подходы на основе МО оказались особенно ценными в определенных контекстах. Например, алгоритм градиентного бустинга обеспечил самую высокую точность прогнозирования острого повреждения почек (ОПП) [12]. Аналогичным образом, Allyn et al. продемонстрировали, что ML-модели значительно превосходят EuroSCORE II и логистическую регрессию в прогнозировании смертности после плановой кардиохирургии, что подчеркивает их потенциал для рутинного использования в клинических условиях [4].

В клапанной хирургии сердца инструменты МО, такие как случайные леса и машины опорных векторов повысили точность классификации рисков. Однако их преимущество перед интуицией хирургов остается спорным, и необходима дальнейшая проспективная проверка в различных клинических условиях [16,17]. При транскатетерной имплантации аортального клапана (TAVI) модели МО продемонстрировали очень высокие показатели точности прогнозирования смертности, достигнув значений площади под ROC-кривой 0,94-0,97, что значительно превосходит традиционные оценки, такие как STS/ACC TAVR. Тем не менее, эти модели менее эффективны при прогнозировании других осложнений, таких как инсульт и сосудистые проблемы [17,18].

ИИ также продемонстрировал перспективность в раннем выявлении осложнений. Модель, разработанная Kalisnik и соавторами продемонстрировала высокие уровни чувствительности и специфичности для выявления острого почечного повреждения в течение 12 ч после операции. Аналогичным образом, инструменты на основе ИИ для выявления делирия у пациентов после кардиохирургических операций показали свою эффективность в выявлении недостаточно распознанных случаев, что подчеркивает их полезность для улучшения периоперационного мониторинга [20].

В области трансплантации сердца ИИ изучается для оптимизации использования органов и прогнозирования исходов после трансплантации. Исследования показывают, что алгоритмы ML превосходят традиционные методы в прогнозировании смертности и осложнений, хотя проблемы с интерпретацией данных и обобщением сохраняются. Например, самообъясняющиеся нейронные сети достигли такой же точности прогнозирования, как и модели глубокого обучения для 1-летней смертности, что подчеркивает потенциал прозрачных, интерпретируемых инструментов ИИ в поддержке принятия клинических решений [21,22,45].

Имеются и менее позитивные результаты, свидетельствующие о том, что методы МО не всегда превосходят традиционные модели из-за ограниченности данных и медленного внедрения [21]. Zeng и соавторы [31] провели исследование с целью оценки потенциальных преимуществ современных методов машинного обучения (МО) по сравнению с традиционными моделями логистической регрессии (ЛР) в прогнозировании внутрибольничной смертности после кардиохирургических операций с использованием внушительной базы данных, включающей 168565 пациентов и внешней валидации. В дополнение к модели логистической регрессии были оценены несколько широко используемых типов моделей машинного обучения, включая (1) деревья решений с градиентным бустингом (GBDT), включающие в себя три современные модели GBDT (XGBoost, CatBoost и LightGBM), (2) случайный лес (RF), (3) наивный байесовский классификатор (NB), и (4) машины опорных векторов (SVC). Исследователи пришли к выводу, что машинное обучение дает лишь ограниченные дополнительные преимущества по сравнению с традиционными стратегиями для предоперационного прогнозирования госпитальной летальности после кардиохирургических операций с использованием обычных клинических переменных. Причинами этому могут быть, во-первых, клинические переменные включенные в модели МО, которые часто являются относительно низкоразмерными, с ограниченными нелинейными отношениями или сложными взаимодействиями. Поэтому модели логистической регрессии могут быть столь же эффективны в использовании простой информации, как и большинство моделей МО, если не лучше. Во-вторых, при прогнозировании смертности после операций на сердце может существовать «эффект потолка», если используются только характеристики предоперационного периода. В отличие от нехирургических исследований, где исход часто зависит от существующих исходных факторов, сама операция часто является единственным наиболее влиятельным фактором для краткосрочных исходов,

поэтому включение интраоперационных или послеоперационных переменных может значительно улучшить эффективность модели.

В целом, ИИ продемонстрировал более высокую точность прогнозирования смертности и стратификации рисков по сравнению с традиционными моделями, причем его применение распространяется на такие специфические задачи в кардиохирургии, как выявление почечного повреждения. Однако для более широкого применения в клинической практике необходимы дальнейшее совершенствование и валидация на различных наборах данных.

В отечественной клинической практике на сегодняшний день отсутствуют свои системы оценки риска кардиохирургических вмешательств. Имеется потребность в разработке отечественной системы стратификации рисков операций на сердце для дальнейшего совершенствования подходов к лечению сердечно-сосудистых заболеваний.

Цель исследования: Разработка модели прогнозирования неблагоприятных событий у пациентов, перенесших кардиохирургическое вмешательство с использованием методов машинного обучения на основе клинико-лабораторных и инструментальных данных.

Объект исследования: когорта пациентов, перенесших оперативное вмешательство на сердце (n=405).

Предмет исследования: характеристики периоперационного периода у кардиохирургических пациентов.

Исследовательский вопрос: Какие характеристики пациента необходимо учитывать в процессе принятия решения о целесообразности кардиохирургического вмешательства?

Задачи исследования:

1. Оценить исходы операций на сердце у пациентов с различной кардиохирургической патологией.

2. Выявить наиболее значимые факторы риска летального исхода у пациентов после операций на сердце в госпитальном периоде.

3. Разработать модель стратификации риска оперативного вмешательства для кардиохирургических пациентов на основе методов машинного обучения.

Гипотеза исследования - модели машинного обучения обладают не меньшей прогностической ценностью при стратификации рисков кардиохирургических вмешательств в сравнении с традиционными методами, основанными на логистической регрессии, и демонстрируют показатель ROC-AUC не менее 0,7

5. Материалы и методы

5.1 Клиническая характеристика

Для решения поставленных задач проведено всесторонний анализ медицинских карт 405 человек, перенесших оперативные вмешательства на открытом сердце.

Диагноз формулировался на основании жалоб, анамнеза, данных физикального обследования, лабораторных и инструментальных методов исследования на основании российских и европейских рекомендаций.

Средний возраст пациентов, вошедших в исследование, на момент госпитализации составлял $61,2 \pm 9,8$ лет. Минимальный возраст на момент оперативного лечения составил 24 лет, а максимальный – 83 лет.

Проведенное исследование носило характер когортного, нерандомизированного, ретроспективного. Гипотеза исследования – Модели машинного обучения обладают не меньшей прогностической ценностью при стратификации рисков кардиохирургических вмешательств в сравнении с традиционными методами, основанными на логистической регрессии, и демонстрируют показатель ROC-AUC не менее 0,7. Дизайн данного исследования можно охарактеризовать как «non-inferiority» (гипотеза о не меньшей эффективности исследуемой методики) (рис. 1). На этапе планирования исследования были определены критерии включения и исключения.

Основные критерии включения в исследование:

- коронарное шунтирование с искусственным кровообращением
- протезирование/пластика клапанов сердца
- протезирование грудной аорты
- сочетанные операции (коронарное шунтирование + протезирование/пластика клапанов и/или протезирование грудной аорты и/или хирургическая абляция предсердий при фибрилляции предсердий)

Основные критерии исключения из исследования:

- миниинвазивное протезирование/пластика клапанов сердца

миниинвазивное коронарное шунтирование

- коронарное шунтирование на работающем сердце
- трансплантация сердца

Конечные точки исследования: летальный исход.

Предоперационная диагностика, медикаментозное лечение проводились согласно стандартам медицинской помощи. Тактика ведения оперативного вмешательства, послеоперационного сопровождения у всех пациентов, включенных в исследование, соответствовала общепринятым стандартам, принятым в Российской Федерации.



Рисунок 1. Дизайн исследования.

Всего в исследование включено 405 пациентов, из них 73,1% (n=296) мужчин и 26,9% (n=109) женщины. Индекс массы тела составил $28,7 \pm 5,1$ кг/м². Ожирение определялось при индексе массы тела равным или больше 30 кг/м². Среди сопутствующих заболеваний отмечались гипертоническая болезнь,

сахарный диабет, хроническая болезнь почек, мультифокальный атеросклероз, хроническая обструктивная болезнь легких, гиперхолестеринемия, эндокардит. Распределение сопутствующей патологии представлено в таблице 1.

Таблица 1. Распределение по сопутствующей патологии (% (абс.))

Заболевания	% (абс.)
Гипертоническая болезнь	83,2% (337)
Ишемическая болезнь сердца	71,4% (289)
Гиперхолестеринемия	25,9% (105)
Сахарный диабет II типа	22,7% (92)
Мультифокальный атеросклероз	12,8% (52)
Хроническая болезнь почек	12,6% (51)
Эндокардит	12,1% (49)
Хроническая обструктивная болезнь легких	5,2% (21)

В анамнезе у пациентов обеих групп встречались курение, инфаркт миокарда, нарушение мозгового кровообращения, чрескожные вмешательства на коронарных артериях (таб. 2).

Таблица 2. Особенности анамнеза пациентов (% (абс.))

Параметры	% (абс.)
Курение	30,6% (124)
Перенесенный инфаркт миокарда	29,6% (120)
Чрескожные вмешательства на коронарных артериях	19,8% (80)
Перенесенное нарушение мозгового кровообращения	8,1% (33)

Оценка тяжести стабильной стенокардии проводилась согласно критериям Канадской Ассоциации Кардиологов (CCS)(таб. 3).

Таблица 3. Степень выраженности стабильной стенокардии по классификации Канадской Ассоциации Кардиологов (CCS) (% (абс.))

Функциональный класс	% (абс.)
Нет стенокардии	29,9% (121)
Безболевая ишемия	2,7% (11)

I ФК	6,7% (27)
II ФК	35,6% (144)
III ФК	24% (97)
IV ФК	1,2% (5)

Тяжесть хронической сердечной недостаточности оценивалась по классификации Нью-Йоркской Ассоциации кардиологов (NYHA) (таб. 4).

Таблица 4. Функциональные классы хронической сердечной недостаточности по классификации Нью-Йоркской Ассоциации кардиологов (NYHA) (абс. (%))

Функциональный класс	% (абс.)
I ФК	8,2% (33)
II ФК	37% (150)
III ФК	49,1% (199)
IV ФК	5,7% (23)

Всем пациентам до и после операции проводилась эхокардиография с целью оценки параметров функционального состояния сердца. На дооперационном этапе фракция выброса левого желудочка составила $57,8 \pm 7,6\%$. Величина давления в легочной артерии составила $38,3 \pm 13,4$ мм.рт.ст.

Пациентам был выполнен различный объем оперативных вмешательств на сердце. Операции носили как изолированный характер, так и сочетанный, когда одномоментно выполнялось несколько процедур на сердце (таб. 5).

Таблица 5. Виды вмешательств на сердце и магистральных сосудах (% (абс.))

Процедура	% (абс.)
Коронарное шунтирование	66,4% (269)
Коррекция аортального порока	44,7% (181)
Коррекция трикуспидального порока	10,4% (42)
Коррекция митрального порока	9,4% (38)

Вмешательство на грудной аорте	6,4% (26)
Пластика левого желудочка	1,7% (7)
Каротидная эндартерэктомия	1,2% (5)
Абляция предсердий	1% (4)
Аортовентрикулопластика	0,3% (1)

5.2. Характеристика набора данных и предобработка

Основой исследования послужили ретроспективные данные 405 пациентов, перенесших операции на открытом сердце. Целевой переменной (target) являлся исход операции: летальный исход (1) или выживание (0).




Рисунок 2. Схема обучения моделей.

5.2.1. Формирование признакового пространства

В состав признаков были включены переменные, соответствующие шкале EuroSCORE II, а также дополнительные клинические маркеры, предложенные в данной работе:

1. Клинико-демографические: возраст, пол, наличие сопутствующих патологий (диабет, ХОБЛ).
2. Гемодинамические показатели: фракция выброса левого желудочка, статус креатинина.
3. Специфические маркеры: легочная гипертензия (ЛГ).
4. Интраоперационные характеристики: объем хирургического вмешательства.

5.2.2. Очистка данных и нормализация

Для минимизации статистического смещения и исключения потери ценных наблюдений была реализована стратегия медианной импутации. Заполнение пропущенных значений медианой, рассчитанной локально для каждого признака, позволило сохранить целостность многомерного признакового пространства без искусственного занижения дисперсии, неизбежного при использовании среднего арифметического. Для номинальных и порядковых переменных использовали модальные значения (Таблица 6).

Таблица 6. Пропуски в данных.

Переменная	Пропущенные значения, %
Возраст	0
Скорость клубочковой фильтрации	4,69
Класс стенокардии	0
Фракция выброса левого желудочка	0,24
Легочная гипертензия	0,49
ФК NYHA	2,71
Объем операции	0
Пол	0
ХОБЛ	0
Мультифокальный атеросклероз	0
Эндокардит	4,44
Диабет	0

ОИМ в анамнезе	0
Аорта	0

Для корректной работы линейных и метрических алгоритмов (Logistic Regression, SVM) была проведена процедура Z-масштабирования (StandardScaler):

$$z = \frac{x - \mu}{\sigma},$$

где μ — среднее значение признака, σ — стандартное отклонение. Для ансамблевых методов на основе деревьев решений данные использовались в исходном масштабе для сохранения интерпретируемости порогов деления в узлах.

5.2.3. Формирование порядковых клинических переменных и категориальная трансформация

С целью приведения данных к виду, позволяющему проводить сравнительный анализ со шкалой EuroSCORE II, а также для повышения устойчивости моделей к возможным выбросам в измерениях, была выполнена процедура дискретизации ключевых количественных признаков. Процесс трансформации включал переход от непрерывных шкал к порядковым категориям (ordinal categories) по четырем основным направлениям:

1. Оценка функции почек

В качестве маркера почечной дисфункции использовалась скорость клубочковой фильтрации (СКФ), рассчитанная по формуле Кокрофта-Голта. На основе пороговых значений EuroSCORE II была сформирована переменная «Нарушение функции почек» с трехбалльной оценкой:

- Категория 0 (Норма): СКФ > 85 мл/мин.
- Категория 1 (Умеренное снижение): СКФ 55–85 мл/мин.
- Категория 2 (Выраженное снижение): СКФ < 55 мл/мин.

2. Систолическая функция левого желудочка

Фракция выброса левого желудочка (ФВЛЖ) была переведена в порядковый признак «Функция ЛЖ», отражающий степень сократительной способности миокарда:

- 0: Сохранная функция (ФВЛЖ > 50%).
- 1: Умеренно сниженная (ФВЛЖ 31–50%).
- 2: Низкая (ФВЛЖ 21–30%).
- 3: Крайне низкая (ФВЛЖ ≤ 20%).

3. Легочная гипертензия (ЛГ)

На основе данных эхокардиографии (давление в легочной артерии, ДЛА) была выделена переменная «ЛГ», классифицирующая пациентов по степени тяжести гемодинамических нарушений малого круга кровообращения:

- 0 (Отсутствует): ДЛА < 31 мм рт. ст.
- 1 (Умеренная): ДЛА 31–55 мм рт. ст.
- 2 (Тяжелая): ДЛА > 55 мм рт. ст.

4. Расчет интегрального показателя «Объем операции»

Для учета совокупной сложности хирургического вмешательства был разработан алгоритм вычисления синтетической переменной «Объем операции». В расчет принимались девять видов вмешательств (АКШ, протезирование клапанов, абляция, пластика ЛЖ и др.).

Логика агрегации признаков представлена следующей иерархией сложности:


- 0: Изолированное аортокоронарное шунтирование (АКШ).
- 1: Одиночное вмешательство на клапанах или крупных сосудах (кроме АКШ).
- 2: Сочетанная операция (ровно два вмешательства из списка).
- 3: Многокомпонентное вмешательство (три и более процедуры).


Таблица 7. Переменные, вошедшие в модели.


Количественные	Категориальные	Номинальные
Возраст	Нарушение функции почек Класс стенокардии Функция ЛЖ ЛГ ФК NYHA Объем операции	Пол ХОБЛ Мультифокальный атеросклероз Эндокардит Диабет ОИМ в анамнезе Аорта

На рисунке 3 представлены распределение 14 переменных, использовавшихся при построении моделей машинного обучения.

Рисунок 3. Распределение переменных, использовавшихся при построении моделей машинного обучения.







Распределение пациентов по возрасту характеризуется правосторонней асимметрией, при этом основная группа пациентов находится в возрастном диапазоне от 55 до 70 лет, что типично для патологий, требующих вмешательства на сердце. Функция почек у подавляющего числа пациентов либо не страдала (36%), либо была умеренно снижена (53,8%). Сократительная функция левого желудочка как правило была сохранна (82%). У большинства пациентов легочная гипертензия отсутствовала (40,7%) либо была умеренно выраженной (47,9%). Уровень стенокардии у большинства пациентов соответствовал II-III (категория 3-4, 59,6%) функциональному классу, а выраженность сердечной недостаточности – III функциональному классу (49,1%). Половина пациентов перенесла одну процедуру на сердце (50,1%). При этом большинство прооперированных были мужчинами (73,1%). Редко встречалась хроническая обструктивная болезнь легких (5,2%). Немало пациентов ранее перенесли инфаркт миокарда (29,6%). Инфекционный эндокардит и мультифокальный атеросклероз достаточно часто встречались среди прооперированных (12,1% и 12,8%, соответственно).

Проведенный корреляционный анализ выявил ряд значимых закономерностей в структуре клинических данных (рисунок 4).




Рисунок 4. Корреляционная матрица.

Выявлена сильная положительная связь переменной «Объем операции» с признаками «ЛГ» ($p = 0.81$) и «ФК NYHA» ($p = 0.74$). Это объясняется патофизиологической логикой: пациенты с тяжелой легочной гипертензией и высоким функциональным классом сердечной недостаточности зачастую нуждаются в сочетанных и более сложных вмешательствах. Признак «Нарушение функции почек» показал умеренную корреляцию с «ЛГ» ($p = 0.38$) и Объемом операции ($p = 0.38$), что может указывать на системный характер поражения органов-мишеней у пациентов со сложной хирургической патологией. Наблюдается ожидаемая умеренная связь между «Функцией ЛЖ»

и «ОИМ в анамнезе» ($p = 0.50$) - снижение фракции выброса как следствие перенесенного инфаркта. Пол и возраст практически не коррелируют с тяжестью состояния (NYHA, ЛГ) или объемом предстоящей операции. Шкала EuroSCORE II, которая сама по себе является логистической регрессией, использует оба этих фактора, поэтому их исключение из исследования нарушило бы логику сравнения, в связи с чем все признаки были оставлены.

5.3. Стратегия разбиения данных и чистота эксперимента

Разделение на подмножества (Train, Validation, Test) производилось по принципу стратификации по целевой переменной y (исход операции). Это обеспечило сохранение идентичной пропорции летальных и благоприятных исходов в каждой из трех выборок:

1. Обучающая выборка (Train, 60%): ~243 пациента (умерших 32). Служила базой для настройки внутренних параметров моделей и обучения алгоритмов в связке с синтетическим оверсэмплингом (SMOTE).
2. Валидационная выборка (Validation, 20%): ~81 пациент (умерших 11). На данных этой группы производился исключительно подбор порога классификации (Threshold optimization), что позволило настроить чувствительность моделей без влияния на итоговые метрики.
3. Тестовая выборка (Test, 20%): ~81 пациент (умерших 11). Выступала в роли «независимого аудитора». Данные из этой выборки полностью изымались на всех этапах обучения и настройки, обеспечивая объективную оценку обобщающей способности финальных алгоритмов.

5.4. Решение проблемы дисбаланса классов

Одной из ключевых сложностей при анализе медицинских данных является естественный дисбаланс классов: частота летальных исходов в кардиохирургии значительно ниже частоты благоприятных исходов.

Обучение классификаторов на несбалансированной выборке приводит к смещению (bias) в сторону мажоритарного класса.

Для решения этой задачи был применен алгоритм SMOTE (Synthetic Minority Over-sampling Technique). В отличие от простого дублирования записей (Random Over-sampling), SMOTE генерирует новые, синтетические объекты.

Алгоритм работы:

1. Для каждого объекта x_i из миноритарного класса вычисляются k ближайших соседей в пространстве признаков.

2. Случайным образом выбирается один из соседей x_{zi} .

3. Создается новый объект x_{new} по формуле:

$$x_{new} = x_i + \lambda * (x_{zi} - x_i),$$

где λ — случайное число в интервале $[0, 1]$.

В данной работе параметр k (число соседей) рассматривался как гиперпараметр и варьировался в диапазоне $[2, 3, 5]$, что позволило адаптировать генерацию данных под локальную плотность признаков в условиях малой выборки.

5.5. Алгоритмы машинного обучения

Для построения прогностических моделей (ПМ I–VI) были выбраны алгоритмы, представляющие различные математические подходы к классификации.

1. Логистическая регрессия (ПМ I): моделирует вероятность исхода через логистическую функцию:

$$P(y=1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta x)}}$$

Использовалась в качестве референсной модели (baseline). Применялась L_2 -регуляризация для минимизации риска мультиколлинеарности между признаками (например, ЛГ и объемом операции).

2. Случайный лес (ПМ IV): Ансамблевый метод, использующий бэггинг (bagging). Модель строит ансамбль независимых деревьев решений, каждое на случайном подмножестве признаков и данных. Итоговый прогноз определяется путем мажоритарного голосования. Метод эффективен для подавления шума и обработки нелинейных связей.

3. Градиентный бустинг (LGBM, XGBoost, CatBoost): Алгоритмы последовательного построения ансамбля, где каждое новое дерево минимизирует ошибку (градиент функции потерь) предыдущих:

$$F_m(x) = F_{m-1}(x) + \eta \gamma_m h_m(x)$$

- CatBoost: применяет симметричные деревья, что снижает риск переобучения.

- LightGBM: использует гистограммный метод распределения признаков, что критично для выделения пороговых значений клинических показателей.

4. Метод опорных векторов (SVM, ПМ VI): Алгоритм строит разделяющую гиперплоскость с максимальным зазором между классами. Для работы с нелинейными медицинскими данными использовалось RBF-ядро (Radial Basis Function):

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

5.6. Оптимизация гиперпараметров и кросс-валидация

Для обеспечения воспроизводимости и достоверности результатов обучение проводилось с использованием 5-фолдовой стратифицированной кросс-валидации (Stratified K-Fold).

Методология:

1. Обучающая выборка разбивается на 5 непересекающихся блоков (фолдов).
2. В каждом фолде сохраняется исходное соотношение классов (смерть/выживание).

3. Модель обучается на 4 блоках и тестируется на 5-м. Процесс повторяется 5 раз.

Поиск оптимальных параметров (Hyperparameter Tuning) осуществлялся методом GridSearchCV. В сетку поиска были включены параметры регуляризации (C , α , λ), глубина деревьев и параметры метода SMOTE. Это гарантирует, что выбранная конфигурация модели является наиболее устойчивой для данного набора данных (таб. 8).

Таблица 8. Пространство перебора гиперпараметров прогностических моделей.

Алгоритм (Прогностическая модель)	Исследуемый гиперпараметр	Описание и назначение	Диапазон значений (Сетка поиска)
Все модели (через SMOTE)	k_neighbors	Число соседей для генерации синтетических данных	[2, 3, 5]
ПМ I (Logistic Regression)	C	Обратная сила регуляризации (L1/L2)	[0.005, 0.01, 0.05, 0.1, 0.5, 1.0]
	penalty	Тип регуляризации (Lasso vs Ridge)	['l1', 'l2']
ПМ II (CatBoost)	depth	Максимальная глубина деревьев	[3, 4, 5]
	l2_leaf_reg	Коэффициент L2-регуляризации функции потерь	[10, 20, 40, 60]
	iterations	Максимальное количество итераций обучения	[200, 350]
ПМ III (LightGBM)	num_leaves	Максимальное количество листьев в одном дереве	[7, 15]
	learning_rate	Скорость обучения (шаг градиентного спуска)	[0.01, 0.03]
	n_estimators	Количество итераций бустинга (ансамбля)	[100, 150, 200]
	min_child_samples	Минимальное количество пациентов, необходимое для создания нового листа	[15, 20, 30]
	model__colsample_bytree	Доля случайно выбираемых	[0.6, 0.8]

		признаков при построении каждого дерева.	
	model__reg_lambda	Коэффициент жесткой L2-регуляризации (Ridge) весов модели	[5, 10, 20, 50]
ПМ IV (Random Forest)	max_depth	Ограничение глубины дерева решений	[3, 5, 7]
	min_samples_leaf	Мин. число объектов в листе (сглаживание)	[4, 6, 8, 12]
	n_estimators	Количество независимых деревьев в лесу	[150, 300]
	max_features	Размер подмножества признаков, анализируемых при каждом разбиении	['sqrt', 0.5]
ПМ V (XGBoost)	max_depth	Глубина ветвления деревьев	[2, 3, 4]
	learning_rate	Коэффициент сжатия (этап адаптации)	[0.01, 0.03]
	n_estimators	Общее число базовых алгоритмов	[100, 150, 200]
	lambda	Штрафной коэффициент L2-регуляризации структурных весов	[5, 10, 20, 50]
	subsample	Доля объектов обучающей выборки, случайно извлекаемая для построения дерева	[0.7, 0.8]
	colsample_bytree	Доля признаков, случайно выбираемая для построения дерева	[0.6, 0.8]
ПМ VI (SVM)	C	Штрафной параметр за ошибки классификации	[0.05, 0.1, 0.5, 1.0, 2.0]
	gamma	Коэффициент ядра, определяющий радиус влияния отдельных опорных векторов	['scale', 0.005, 0.01]
	kernel	Тип функции ядра (нелинейное преобразование)	['rbf']

5.7. Метрики качества и интерпретация моделей

В условиях дисбаланса классов метрика Accuracy (доля верных ответов) не является информативной. В работе использован комплекс метрик:

1. ROC-AUC: площадь под кривой зависимости чувствительности (TPR) от доли ложноположительных ответов (FPR). Позволяет оценить качество ранжирования пациентов по степени риска.

2. Индекс Юдена (J): использовался для определения оптимального порога отсечения вероятности:

$$J = \text{Sensitivity} + \text{Specificity} - 1 \rightarrow \max$$

Этот подход позволяет найти баланс между риском пропуска критического пациента и частотой ложных тревог.

3. Precision, Recall и F1-мера: рассчитаны на тестовой выборке для оценки практической применимости моделей.

4. Индекс Брайера (Brier Score): применен для оценки качества калибровки выдаваемых моделью вероятностей риска. Математически представляет собой среднеквадратичную ошибку предсказаний:

$$BS = \frac{1}{N} \sum_{t=1}^N (p_t - y_t)^2,$$

где p_t — предсказанная моделью вероятность летального исхода для t -го пациента, а $y_t \in \{0, 1\}$ — реальный фактический исход. Минимизация индекса Брайера критически важна для клинической практики, так как она гарантирует адекватность рассчитанных процентов риска (например, если модель прогнозирует риск летальности 15%, это должно соответствовать реальной частоте исходов в данной подгруппе, исключая недо- или переоценку рисков).

Интерпретация через значения SHAP:

Для преодоления проблемы «черного ящика» при использовании бустингов применен метод SHAP (SHapley Additive exPlanations). Метод основан на расчете вклада каждого признака в отклонение прогноза от

среднего значения по выборке. Значение SHAP для признака x_i рассчитывается как:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N|-|S|-1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Все расчеты проводились на языке Python 3.12, с использованием библиотек scikit-learn, imblearn, LightGBM, XGBoost, CatBoost и SHAP.

6. Результаты.

6.1. Архитектурное проектирование и программная реализация мультимодельного комплекса стратификации рисков

В рамках данного исследования была разработана и программно реализована мультимодельная система поддержки принятия врачебных решений (СППВР), ориентированная на индивидуальное прогнозирование риска возникновения тяжелых послеоперационных осложнений у пациентов кардиохирургического профиля. Проектирование расчетного ядра системы осуществлялось на языке Python с использованием специализированных библиотек анализа данных и машинного обучения (scikit-learn, xgboost, lightgbm, catboost, imbalanced-learn).

Основным методологическим принципом построения вычислительного конвейера стало создание сквозных изолированных пайплайнов обработки информации на базе класса `ImbPipeline` (пакет `imblearn.pipeline`). Использование интегрированных конвейеров вместо изолированных процедур обработки позволило инкапсулировать этапы нормализации, балансировки классов и финальной классификации в единый программный объект. Это обеспечило строгое разделение потоков данных и полностью исключило потенциальный эффект утечки информации (*data leakage*) из валидационных и тестовых подмножеств на этапе обучения моделей.

Базовая архитектура разработанного сквозного конвейера реализована в виде параметризованной функции `get_imb_pipeline(clf, scale)` и включает в себя следующие последовательные функциональные блоки:

1. Блок стандартизации признакового пространства (`StandardScaler`): Осуществляет центрирование и масштабирование векторов признаков, приводя их к нулевому математическому ожиданию и единичной дисперсии. Данный шаг активировался адаптивно (`scale=True`) только для алгоритмов, критичных к метрическим расстояниям и масштабу шкал (линейные модели и ядерные методы опорных векторов).

2. Блок адаптивного оверсэмплинга миноритарного класса (SMOTE): Направлен на преодоление дисбаланса целевых классов в исходной когорте пациентов. Алгоритм осуществляет направленный синтез векторов «виртуальных пациентов» с осложнениями в многомерном пространстве признаков, используя интерполяцию между реальными объектами и их ближайшими соседями. С целью оптимизации геометрии разделяющей поверхности параметр количества ближайших соседей (`smote__k_neighbors`) подбирался динамически в процессе кросс-валидации.

3. Блок классификатора (`model`): Финальный узел конвейера, принимающий трансформированную и сбалансированную выборку для обучения решающих правил.

С целью проведения всестороннего сравнительного анализа в контур вычислительного ядра были интегрированы шесть разнородных классов предикативных алгоритмов (Прогностические модели ПМ I–VI), обладающих различными математическими механизмами аппроксимации целевых зависимостей:

ПМ I (Логистическая регрессия — `LogisticRegression`): Представляет класс параметрических линейных классификаторов. В качестве оптимизационного алгоритма использован метод `liblinear`, адаптированный для выборок малого и среднего объема. Максимальное число итераций сходимости установлено на уровне `max_iter=3000` для гарантированного достижения глобального экстремума функции правдоподобия. Роль модели заключается в извлечении стабильных базовых линейных трендов.

ПМ II (Случайный симметричный бустинг — `CatBoostClassifier`): Высокотехнологичный ансамбль, строящийся на базе регулярных (симметричных) решающих деревьев. Модель оптимизирована под работу с разнородными медицинскими данными, устойчива к шуму и включает встроенный механизм ранней остановки (`early_stopping_rounds=40`) по

динамике логарифмической функции потерь на отложенном фолде для предотвращения переобучения.

ПМ III (Легковесный градиентный бустинг — `LGBMClassifier`): Ансамблевый алгоритм, использующий гистограммный подход к квантованию признаков и листовой рост деревьев (*leaf-wise*), что обеспечивает высокую скорость вычислений и гибкость при улавливании сложных нелинейных взаимодействий факторов риска.

ПМ IV (Классический случайный лес — `RandomForestClassifier`): Представитель бэггинговых архитектур, формирующий прогноз посредством усреднения предсказаний большого массива глубоких независимых деревьев решений, строящихся на случайных подмножествах пациентов и признаков.

ПМ V (Экстремальный градиентный бустинг — `XGBClassifier`): Реализует строгое последовательное построение ансамбля деревьев на основе градиентного спуска в функциональном пространстве с явным вычислением гессiana и оптимизацией целевой функции `eval_metric='logloss'`.

ПМ VI (Метод опорных векторов — `SVC`): Представитель непараметрических метрических алгоритмов. Перевод исходных признаков в бесконечномерное пространство для поиска оптимальной разделяющей гиперплоскости осуществляется за счет радиально-базисной функции ядра (`kernel='rbf'`). Для обеспечения клинической применимости алгоритма активирован расчет вероятностных калибровок по методу Платта (`probability=True`).

Оптимизация архитектуры и поиск векторов наилучших гиперпараметров для всех шести прогностических моделей проводились в рамках единого скоординированного процесса перебора по умной сетке (`GridSearchCV`). В качестве валидационной стратегии использовалась жесткая 5-кратная стратифицированная кросс-валидация (`StratifiedKFold`, `n_splits=5`) со случайным перемешиванием данных (`shuffle=True`, `random_state=42`), гарантирующая неизменность доли критических пациентов в каждом

анализируемом сегменте выборки. Целевым критерием оптимизации (*scoring*) была выбрана максимизация площади под рок-кривой (*roc_auc*), что обеспечивает наилучшую разделительную силу системы в условиях сильного дисбаланса классов. Расчеты производились в многопоточном режиме (*n_jobs=-1*), задействующем полный пул доступных вычислительных ядер (Листинг 1).

6.2. Анализ результатов подбора гиперпараметров и интерпретация оптимальных конфигураций моделей

В ходе проведения многопоточного решетчатого поиска на основе 5-кратной стратифицированной кросс-валидации были определены наилучшие векторы гиперпараметров для каждой из шести исследуемых прогностических моделей. Суммарно в рамках эксперимента было обучено и оценено более 4600 вычислительных конфигураций конвейеров.

Сводные данные по извлеченным оптимальным параметрам систематизированы в таблице 9.

Таблица 9. Оптимальные конфигурации параметров сквозных конвейеров, определенные в ходе решетчатого поиска.

Шифр модели	Базовый алгоритм	Общее число итераций (Fits)	Найденный оптимальный вектор гиперпараметров (<i>best_params_</i>)
ПМ I	LogisticRegression	180	{ <i>'model__C'</i> : 0.01, <i>'model__penalty'</i> : 'l2', <i>'smote__k_neighbors'</i> : 2}
ПМ II	CatBoostClassifier	240	{ <i>'model__depth'</i> : 4, <i>'model__iterations'</i> : 200, <i>'model__l2_leaf_reg'</i> : 60, <i>'smote__k_neighbors'</i> : 5}
ПМ III	LGBMClassifier	2880	{ <i>'model__colsample_bytree'</i> : 0.8, <i>'model__learning_rate'</i> : 0.03, <i>'model__min_child_samples'</i> : 20, <i>'model__n_estimators'</i> : 150, <i>'model__num_leaves'</i> : 15, <i>'model__reg_lambda'</i> : 20, <i>'smote__k_neighbors'</i> : 5}
ПМ IV	RandomForestClassifier	480	{ <i>'model__max_depth'</i> : 7, <i>'model__max_features'</i> : 'sqrt', <i>'model__min_samples_leaf'</i> : 12,

			'model__n_estimators': 300, 'smote__k_neighbors': 5}
ПМ V	XGBClassifier	2880	{'model__colsample_bytree': 0.8, 'model__lambda': 10, 'model__learning_rate': 0.03, 'model__max_depth': 2, 'model__n_estimators': 200, 'model__subsample': 0.8, 'smote__k_neighbors': 5}
ПМ VI	SVC	150	{'model__C': 1.0, 'model__gamma': 'scale', 'model__kernel': 'rbf', 'smote__k_neighbors': 3}

Анализ структуры извлеченных векторов параметров позволяет сделать несколько выводов:

1. Тенденция к жесткой структурализации и консерватизму ансамблей:

Для модели ПМ V (XGBoost) оптимальной оказалась минимальная глубина дерева $\text{max_depth}=2$, что фактически сводит базовые алгоритмы к «пням решений» (*decision stumps*). Это свидетельствует о том, что аддитивная композиция очень простых нелинейных правил обеспечивает более устойчивое обобщение, чем глубокие разветвленные графы.

Для ПМ II (CatBoost) глубина зафиксировалась на уровне $\text{depth}=4$, а для ПМ IV (Random Forest) — $\text{max_depth}=7$. Совместно со строгим ограничением минимального объема терминального листа у случайного леса ($\text{min_samples_leaf}=12$ пациентов) и LightGBM ($\text{min_child_samples}=20$ пациентов), это подтверждает клиническую разнородность выборки: алгоритмы умышленно блокируют выделение мелких, потенциально шумовых подгрупп пациентов, ориентируясь на крупные патофизиологические паттерны.

2. Жесткая регуляризация весов.

В алгоритмах градиентного бустинга алгоритм оптимизации выбрал верхние границы штрафования. Так, для CatBoost штраф на листья составил

`l2_leaf_reg=60` (при базовом значении 3), а для LightGBM регуляризатор весов равен `reg_lambda=20`.

Аналогично, в ПМ I (Логистическая регрессия) было выбрано крайне малое значение коэффициента регуляризации $C=0.01$ при сохранении гладкого L₂-штрафа (`penalty='l2'`). В математическом контексте это означает сильное искусственное сжатие (*shrinkage*) пространства коэффициентов модели к нулю, что предотвращает неустойчивость оценок при возможной мультиколлинеарности клинических факторов (например, корреляции возраста, фракции выброса левого желудочка и коморбидных фонов).

3. Специфика стохастического сэмплирования пространства:

Оптимальные параметры ансамблей градиентного бустинга подпространств признаков зафиксировались на уровнях `colsample_bytree=0.8` (XGBoost, LightGBM) и `max_features='sqrt'` (Random Forest). Программное ограничение на использование лишь части доступных клинических предикторов при построении каждого отдельного узла сплита обеспечивает декорреляцию базовых деревьев. Это значительно снижает общую дисперсию (*variance*) финального мета-предсказания.

4. Зависимость геометрии SMOTE от природы классификатора:

Крайне примечательно поведение параметра `smote_k_neighbors`, описывающего топологию локального синтеза виртуальных объектов:

Для линейной модели (LR) оптимальным стало минимальное окружение `k_neighbors=2`, что сужает зону генерации и делает границу раздела более локальной и резкой.

Для мощных нелинейных ансамблей (CatBoost, LightGBM, XGBoost, Random Forest) оптимум сместился к `k_neighbors=5`. Это обеспечивает широкое многомерное «облако» синтетических прецедентов, которое эффективно сглаживает ступенчатые границы разделения, свойственные древесным архитектурам.

Метрический метод ПМ VI (SVM) зафиксировал промежуточное компромиссное значение $k_neighbors=3$ при умеренном штрафе $C=1.0$ и автоматическом масштабировании ядра ($gamma='scale'$), что указывает на гладкую, устойчивую форму сформированной разделяющей гиперплоскости в спрямляющем пространстве.

Таким образом, результаты подбора гиперпараметров полностью подтверждают правила теории машинного обучения. Так как медицинские данные часто ограничены по объему и содержат много шума, алгоритмы умышленно снижают сложность базовых моделей и используют жесткие штрафы (регуляризацию). Это позволяет моделям избегать переобучения и сохранять высокую точность на новых данных.

6.3. Оценка качества моделей и методика адаптивного выбора порогов классификации

Любая прогностическая модель на выходе выдает не готовый диагноз, а непрерывную величину — вероятность (от 0 до 1) развития послеоперационных осложнений. Чтобы превратить эту вероятность в конкретное бинарное решение («высокий риск» или «низкий риск»), необходимо установить порог разделения. Стандартный порог, равный 0.5, в медицинских задачах обычно неэффективен из-за сильного численного превосходства выживших пациентов над пациентами с осложнениями.

Для решения этой проблемы в данном фрагменте исследования реализован двухэтапный процесс финальной оценки моделей:

1. Адаптивный поиск порога по критерию Юдена:

С помощью функции `find_best_threshold` для каждого алгоритма рассчитывается индивидуальный порог разделения. Математический смысл критерия Юдена заключается в поиске такой точки на ROC-кривой, где баланс между чувствительностью (способностью модели находить реальные

осложнения) и специфичностью (способностью не путать их с нормой) является максимальным.

2. Расчет финальных метрик на независимом тест-сете:

- Оптимальный порог классификации подбирается исключительно на основе валидационной выборки (X_{val} , y_{val}).
- Финальное тестирование и расчет метрик (Recall, Precision, F1-score, ROC-AUC) выполняются строго на независимой тестовой выборке (X_{test} , y_{test}), которая была полностью скрыта от моделей в процессе обучения и калибровки.

Такой подход гарантирует объективность полученных результатов. Метрики, посчитанные на независимом тест-сете, показывают реальное качество работы созданной модели и защищают исследование от случайного завышения точности (переобучения) при проверке на новых пациентах. Сводный результат вычислений агрегируется в итоговую таблицу и ранжируется по метрике ROC-AUC для выявления наиболее эффективного алгоритма.

6.4. Сравнительный анализ эффективности прогностических моделей на независимой тестовой выборке

После этапа тонкой настройки гиперпараметров и адаптивной калибровки индивидуальных порогов отсечения по критерию Юдена была проведена финальная оценка обобщающей способности всех шести разработанных прогностических моделей (ПМ). Тестирование выполнялось на изолированной тестовой выборке (X_{test}), содержащей реальные клинические исходы кардиохирургических пациентов.

Сводные метрики эффективности классификации, ранжированные по дискриминационной силе (ROC-AUC), представлены в таблице 10.

Таблица 10. Сравнительные метрики качества прогнозных моделей на независимых тестовых данных.

Прогностическая модель (Алгоритм)	Порог отсечения (Threshold)	Чувствительность (Recall)	Точность (Precision)	F1-мера (F1-Score)	Площадь под ROC-кривой (ROC-AUC)
ПМ IV (Random Forest)	0.395	0.7273	0.3200	0.4444	0.8494
ПМ III (LightGBM)	0.299	0.7273	0.2963	0.4211	0.8429
ПМ V (XGBoost)	0.294	0.7273	0.2963	0.4211	0.8325
ПМ VI (SVM)	0.183	0.7273	0.3200	0.4444	0.8286
ПМ I (Logistic Regression)	0.498	0.9091	0.2778	0.4255	0.8208
ПМ II (CatBoost)	0.342	0.7273	0.3810	0.5000	0.8182

Анализ метрических профилей позволяет выявить несколько ключевых закономерностей.

Лидером по интегральному качеству ранжирования пациентов стал случайный лес ПМ IV (Random Forest) с показателем ROC-AUC = 0.8494. Второе и третье места заняли бустинги ПМ III (LightGBM) с ROC-AUC = 0.8429 и ПМ V (XGBoost) с ROC-AUC = 0.8325. Высокие результаты этих моделей обусловлены их способностью выявлять сложные нелинейные паттерны и межпризнаковые взаимодействия в клинических данных. Тот факт, что все модели преодолели порог 0.80, свидетельствует об их высокой прогностической надежности согласно общепринятой медицинской классификации качества систем прогнозирования.

Внимания заслуживает поведение линейной модели ПМ I (Logistic Regression). Она продемонстрировала очень высокий уровень полноты прогноза — Recall = 0.9091. Это означает, что алгоритм успешно идентифицирует более 90% умерших пациентов (минимальный риск «пропуска цели»). При этом оптимальный порог Юдена для ПМ I зафиксировался на уровне 0.498 (практически стандартные 0.5). В клинической практике такой профиль делает логистическую регрессию хорошим инструментом для первичного скрининга: выявляет максимальное

число потенциально летальных исходов. Однако, зафиксирован неудовлетворительный индекс Брайера = 0.2358, близкий к порогу случайного угадывания 0.25), что указывает на системное завышение вероятностей (гипердиагностику) ради минимизации пропуска критических пациентов.

Несмотря на то, что модель ПМ II (CatBoost) оказалась на последнем месте по метрике ROC-AUC (0.8182), она показала наивысшую точность классификации — Precision = 0.3810 и, как следствие, наилучший гармонический баланс F1-Score = 0.5. В условиях сильного дисбаланса классов (когда число благополучных исходов кратно превышает число осложнений) значение точности 38% является высоким результатом. Это означает, что почти каждая третья тревога модели является истинной.

Показательно смещение оптимальных порогов классификации. Для ПМ VI (SVM) порог опустился до 0.183. Это прямое следствие математической структуры метода опорных векторов и генерации синтетических векторов через SMOTE: модель вынуждена сильно снижать границу принятия решений, чтобы захватить геометрическую область целевого класса. Для большинства нелинейных моделей (RF, LGBM, XGBoost, CatBoost) пороги зафиксировались в диапазоне от 0.29 до 0.39, что наглядно подтверждает неэффективность стандартного порога 0.5 для несбалансированных медицинских выборок и доказывает обязательность применения процедуры оптимизации Юдена.

Таким образом, для рутинного применения более предпочтительным решением выступает ПМ IV (Random Forest). Обладая максимальной дискриминационной способностью (ROC-AUC = 0.8494), случайный лес обеспечивает наилучший компромисс между выявлением пациентов группы риска (Recall = 72.7%) и снижением нагрузки на персонал за счет контроля ложных срабатываний (Precision = 32.0%). В отличие от бустинговых моделей, ПМ IV исторически более устойчива к шуму в медицинских данных и менее склонна к переобучению при изменении потока пациентов.

В условиях, когда ключевым приоритетом является абсолютное исключение пропусков терминальных состояний (риск ложноотрицательного прогноза), может быть обосновано применение ПМ I (LR). Обладая наивысшей чувствительностью ($\text{Recall} = 90.9\%$), данная модель эффективно функционирует в качестве первичного диагностического фильтра высокого уровня надежности.

Для визуальной оценки дискриминационной способности разработанных моделей на независимых тестовых данных были построены совмещенные операционные характеристики (рисунок 5).




Рисунок 5. ROC-кривые на тестовой выборке.

Кривая случайного леса стабильно доминирует на большинстве участков координатного пространства, особенно в клинически значимой зоне «низкого уровня ложных тревог» (где значение FPR находится в диапазоне от 0.0 до 0.3). Она ближе всего прижимается к идеальной верхней левой точке (0, 1). Профиль логистической регрессии имеет характерный более пологий, «сглаженный» изгиб. Она заметно уступает ансамблям на начальном отрезке (при малых значениях FPR), однако в правой части графика (при увеличении допустимой доли ложных тревог) её кривая резко уходит вверх, обеспечивая ту самую пиковую чувствительность в 90.9%.

6.5. Анализ устойчивости разработанных моделей и оценка выраженности эффекта переобучения

С целью математической оценки устойчивости разработанных классификаторов был проведен сквозной мониторинг метрики ROC-AUC на трех изолированных подмножествах данных: обучающем (Train), валидационном (Val) и независимом тестовом (Test). В качестве количественного индикатора обобщающей способности моделей использовалась разность (дельта) между качеством обучения и качеством тестирования:

$$\Delta = \text{ROC-AUC}_{\text{Train}} - \text{ROC-AUC}_{\text{Test}}$$

Значение $\Delta \rightarrow 0$ свидетельствует об идеальном балансе модели, в то время как высокие положительные значения указывают на переобучение. Результаты расчетов сведены в таблицу 11.

Таблица 11. Мониторинг стабильности метрики ROC-AUC на различных этапах вычислительного эксперимента.

Название модели (Алгоритм)	ROC-AUC Train	ROC-AUC Val	ROC-AUC Test	Δ (Train - Test)	Brier Score	Статус устойчивости
ПМ I (Logistic Regression)	0.8522	0.7234	0.8208	0.0314	0.2358	Абсолютная устойчивость

ПМ IV (Random Forest)	0.9180	0.7597	0.8494	0.0686	0.1245	Высокая стабильность
ПМ V (XGBoost)	0.9034	0.7136	0.8325	0.0709	0.1233	Удовлетворительная
ПМ III (LightGBM)	0.9155	0.7649	0.8429	0.0726	0.1202	Удовлетворительная
ПМ II (CatBoost)	0.9362	0.7597	0.8182	0.1181	0.1228	Склонность к переобучению
ПМ VI (SVM)	0.9739	0.7714	0.8286	0.1454	0.1251	Критическое переобучение

Логистическая регрессия продемонстрировала минимальное падение качества: $\Delta = 0.0314$. Значение ROC-AUC на тесте 0.8208 осталось практически на уровне обучения 0.8522. Логистическая регрессия подтверждает статус стабильного «базового решения» (*baseline*).

В группе нелинейных моделей лучшую устойчивость показал случайный лес (ПМ IV) с $\Delta = 0.0686$. При очень высоком качестве обучения ROC-AUC = 0.9180 модель сохранила сильный результат на тесте 0.8494 при сохранении высокой стабильности. Дельта между обучением и тестом составила всего 0.0686, что указывает на удовлетворительную устойчивость ансамбля к шуму в медицинских данных. Индекс Брайера = 0.1245, свидетельствует о хорошей калибровке индивидуального прогноза и надежности выдаваемых процентов риска для конкретного пациента.

Бустинги LightGBM (ПМ III) и XGBoost (ПМ V) показали сопоставимую динамику ($\Delta \approx 0.071 - 0.073$). Контроль переобучения здесь был достигнут за счет оптимизации параметров регуляризации (параметры λ , α и ограничение глубины деревьев), выполненной на шаге случайного поиска по сетке.

CatBoost (ПМ II) показал выраженную дельту ($\Delta = 0.1181$). Алгоритм продемонстрировал глубокое переобучение на этапе обучения (ROC-AUC = 0.9362), однако на тестовых данных просел до 0.8182. Для медицинских задач дельта больше 0.10 считается тревожным сигналом, указывающим на

избыточную сложность внутренних симметричных деревьев для данного объема выборки.

SVM (ПМ VI) оказался наименее стабильным алгоритмом с критическим падением метрики $\Delta = 0.1454$. На обучающей выборке модель зафиксировала «идеальный» результат (ROC-AUC = 0.9739), что связано со спецификой работы RBF-ядра и оверсэмплингом (SMOTE). Алгоритм фактически «подстроил» разделяющую гиперплоскость под сгенерированные синтетические объекты, из-за чего частично потерял обобщающую способность на реальном тесте (ROC-AUC = 0.8286).

При анализе таблицы отчетливо виден паттерн: показатели ROC-AUC Val у всех моделей ниже, чем показатели как на Train, так и на Test. Возможные причины этого:

- Малый объем валидационного подмножества. Из-за жесткого разбиения данных и сильного дисбаланса классов в валидационную выборку попадает относительно небольшое число пациентов с истинно положительным исходом (летальностью). В условиях малого количества целевых событий любое единичное ложное срабатывание или пропуск резко опускают площадь под ROC-кривой.
- Случайный сдвиг распределений (Data Shift): Тестовая выборка по своей структуре и плотности распределения ключевых признаков оказалась ближе к генеральной совокупности обучающей выборки, чем валидационный сплит.
- Роль валидации как регуляризатора. Калибровка порогов Юдена происходила по «пессимистичной» валидационной выборке, что сработало как регуляризатор. Модели не переобучились под валидацию, что в итоге обеспечило высокий и чистый результат на независимом тесте.

При анализе индекса Брайера, можно отметить, что бустинги и случайный лес показали хорошую калибровку. Значения в районе 0.12 говорят о том, что эти модели выдают достаточно реалистичные вероятности риска

летальности. При этом ПМ III (LightGBM) оказалась самым точным калибратором. Обращает на себя внимание индекс Брайера логистической регрессии, вплотную приблизился к критической отметке случайного угадывания (0.25), что в сочетании с высоким Recall = 0.9091 указывает на то, что модель сдвинула свои предсказания в сторону высокого риска (стала гипердиагностировать), чтобы не пропустить ни одного больного. Классификация осталась неплохой, но реальные вероятности сильно завышены, что и отразил плохой индекс Брайера.

6.6. Сравнительный анализ значимости признаков

Чтобы обосновать медицинскую ценность моделей и уйти от концепции «черного ящика», мы оценили значимость каждого клинического признака. Специфика используемого ансамбля алгоритмов потребовала двух подходов к верификации:

1. Для линейной модели (ПМ I - LR): Анализ стандартизированных коэффициентов регрессии, определяющих направление (знак коэффициента) и силу влияния фактора на логарифм шансов летального исхода.
2. Для нелинейных моделей (ПМ II – ПМ VI): Оценка относительного информационного вклада признака, нормированного в процентном выражении ($\Sigma = 100\%$).

Для нивелирования алгоритмических смещений отдельных архитектур (например, склонности Random Forest переоценивать непрерывные признаки или чувствительности LightGBM к разреженным категориальным переменным) было рассчитано среднее арифметическое относительной важности по всем четырем ансамблевым моделям. Результаты сводного анализа представлены в таблице 12. Графическая интерпретация представлена на рисунке 6.

Таблица 12. Сводная матрица значимости признаков в структуре моделей прогнозирования госпитальной летальности.

Признак	ПМ I (LR, Coef)	ПМ II (CatBoos t, %)	ПМ III (LGBM , %)	ПМ IV (RF, %)	ПМ V (XGBoost , %)	ПМ VI (SVM , %)	Консенсус -важность (%)
Объем операции	0.29 6	20.082	15.017	19.74 9	15.834	15.87 3	17.311
Класс стенокардии	0.19 9	17.540	10.012	10.49 6	14.963	16.29 8	13.862
ФК NYHA	0.27 7	10.258	8.731	14.24 1	10.263	21.03 2	12.905
ЛГ	0.23 3	6.893	6.752	14.14 1	16.021	9.042	10.570
ОИМ в анамнезе	0.15 8	14.933	9.546	12.64 4	12.562	0.000	9.937
Возраст	- 0.08 1	4.368	11.176	3.853	2.685	11.13 9	6.644
Пол	- 0.00 1	6.316	11.758	3.240	3.668	6.746	6.346
Нарушение функции почек	0.19 0	4.656	7.451	7.872	7.616	2.154	5.950
Функция ЛЖ	0.13 9	5.674	4.773	7.499	5.617	1.417	4.996
Мультифокальны й атеросклероз	0.07 1	4.721	5.471	1.986	4.420	0.000	3.320
Диабет	0.02 1	3.057	4.540	1.728	3.373	3.231	3.186
Аорта	0.04 2	0.205	1.048	0.565	0.544	7.908	2.054
Эндокардит	0.00 9	0.239	2.794	1.080	0.372	3.656	1.628
ХОБЛ	0.00 7	1.058	0.931	0.908	2.062	1.502	1.292




Рисунок 6. Важность признаков.

Удалось выделить четыре признака, суммарный вклад которых составляет почти 55% всей прогностической силы ансамблей:

«Объем_операции» (17.311%): этот признак стабилен во всех моделях (от 15% в XGBoost до 20% в CatBoost). Высокий положительный коэффициент

в LR (0.296) подтверждает: усложнение и утяжеление хирургического вмешательства (например, сочетание АКШ с протезированием клапанов или резекцией аневризмы) линейно и нелинейно увеличивает риск неблагоприятного исхода.

«Класс_стенокардии» (13.862%) и «ФК_NYHA» (12.905%): два фундаментальных показателя тяжести хронической ишемии миокарда и сердечной недостаточности. При этом SVM отдал «ФК_NYHA» наивысший приоритет среди всех признаков (21.032%). Это говорит о том, что в высокоразмерном пространстве SVM именно функциональный класс по NYHA служит ключевым фактором для проведения разделяющей гиперплоскости между группами риска. Линейная модель (LR) также оценивает их высоко (0.199 и 0.277, соответственно).

«ЛГ» (Легочная гипертензия — 10.570%): стабильно удерживает позиции во всех моделях. Присутствие ЛГ в топке клинически абсолютно оправдано, так как повышенное давление в легочной артерии — маркер запущенного поражения сердца и высокого риска правожелудочковой недостаточности в раннем послеоперационном периоде.

Имеются различия в «взглядах» моделей на одни и те же данные. Это доказывает необходимость использования ансамблей. Так, консенсус дает признаку «ОИМ_в_анамнезе» немалые 9.937%. Деревья оценивают его в районе 9.5% - 14.9%, а LR подтверждает значимость коэффициентом 0.158, однако SVM выдает ровно 0.000%. Скорее всего, информация об инфаркте в пространстве SVM оказалась избыточной (скоррелированной) — её нелинейно "поглотили" такие признаки, как «Класс_стенокардии», «Функция_ЛЖ» и «ФК_NYHA». Деревья же (особенно CatBoost — 14.933%) умеют строить жадные изолированные сплиты по бинарным флагам, вытаскивая из них максимум чистой энтропии.

В логистической регрессии коэффициенты для Возраста (-0.081) и Пола (-0.001) близки к нулю или даже уходят в слабый минус. Однако в LightGBM

и SVM оба признака совершают резкий скачок вверх, забирая по 11% важности каждый. В чистом виде (линейно) возраст и пол не связаны с летальностью напрямую (что и показала LR), но они обладают значительным эффектом синергии (взаимодействия). Например, сам по себе возраст в 50 лет — это не приговор, но «Возраст > 70 лет» в сочетании с «Полом = Женский» и «Диабетом» создает группу риска. Деревья и RBF-ядро SVM мгновенно улавливают эти паттерны "стыковки" признаков, поэтому их Permutation и Split-важности для этих переменных оказались в разы выше.

Нижняя часть таблицы (от «Диабета» до «ХОБЛ») содержит признаки с важностью менее 4%. «Диабет», «Эндокардит», «ХОБЛ» в классических шкалах (EuroSCORE II) эти сопутствующие патологии имеют фиксированные веса, в нашей когорте пациентов их изолированное влияние мало. На фоне общего безразличия деревьев (0.2% - 1.0%) нелинейный SVM выделил патологию аорты как значимый фактор. Это может указывать на то, что признак «Аорта» критичен для очень небольшой, специфической подгруппы пациентов (например, расслоения или аневризмы), которую SVM смог изолировать в своем пространстве, а деревья "замылили" на фоне общего объема выборки.

Таким образом, установлено, что ключевыми предикторами госпитальной летальности с совокупным вкладом порядка 55% являются тяжесть планируемого вмешательства (Объем операции) и степень декомпенсация статуса пациента («Класс стенокардии», «ФК NYHA», «Легочная гипертензия»). Выявленные расхождения (в частности, нулевой вес признака "ОИМ в анамнезе" для модели SVM при его высокой значимости в CatBoost — 14.933%) указывают на привлекательность применения гетерогенного ансамбля моделей. Линейные методы (LR) оказались неспособны зафиксировать скрытые нелинейные эффекты взаимодействия таких признаков, как «Возраст» и «Пол», в то время как нелинейные

структуры (LGBM, SVM) уловили нелинейные взаимодействия признаков, что повышает ценность итогового диагностического решения.

Классические методы оценки значимости признаков (Feature Importance), основанные на частоте расщепления в деревьях решений (Split Importance) или перестановочном критерии (Permutation Importance), позволяют определить лишь совокупную интегральную важность каждого предиктора. Однако они обладают рядом неустранимых ограничений: данные метрики не раскрывают характер (направленность) влияния признака на целевую переменную, не учитывают индивидуальный профиль пациента и часто оказываются смещенными в условиях мультиколлинеарности данных. В свою очередь, построение сложных нелинейных ансамблей (CatBoost, LightGBM, XGBoost, Random Forest) и ядерных методов (SVM) порождает проблему «черного ящика» (black-box models), затрудняя клиническую интерпретацию и трансляцию полученных моделей в реальную медицинскую практику. Для преодоления указанных ограничений и обеспечения строгой локальной и глобальной объяснимости (explainability) разработанных прогностических моделей в настоящем исследовании был применен метод SHAP (SHapley Additive exPlanations), основанный на концепции кооперативных игр Л. Шепли. Математическое преимущество данного подхода заключается в соблюдении аксиом локальной точности, монотонности и симметрии, что гарантирует единственность и математическую строгость решения при распределении «выигрыша» (сдвига прогностической вероятности) между предикторами.

В рамках работы для каждой из обученных прогностических моделей (ПМ I — ПМ VI) был реализован изолированный расчет значений SHAP на тестовой выборке с привлечением специализированных математических модулей: LinearExplainer — для выявления изолированных линейных эффектов в логистической регрессии (ПМ I); TreeExplainer — для точного и высокоскоростного анализа древесных ансамблей (ПМ II – ПМ V);

KernelExplainer (в комбинации с аппроксимацией фонового распределения методом k-средних) — как универсальный аппроксиматор для дешифровки геометрии многомерного пространства метода опорных векторов (ПМ VI).

Визуализация результатов выполнена с помощью диаграмм рассеяния SHAP Summary Plots, отражающих не только ранг значимости каждого клинико-анамнестического показателя, но и знак, а также выраженность его влияния на персональный риск развития госпитальной летальности у кардиохирургических пациентов.




Рисунок 7. SHAP-анализ признаков.

Для «Объема операции», «ФК NYHA» и «ЛГ» мы видим достаточно четкое разделение: красные точки сдвинуты вправо, синие — влево. То есть, чем выше функциональный класс или тяжелее операция, тем сильнее модель завышает риск. На большинстве графиков мы видим четкое разделение верхних признаков на группы, при этом высокие градации признаков повышают риски, а низкие — нет. Но, чем ниже располагается признак (и чем менее значим), тем менее группы отстоят друг от друга. Это обусловлено нелинейным характером построенных моделей (в частности, ансамблей деревьев решений и ядерных методов). Влияние признаков на низких позициях на финальный риск носит комплексный, зависимый от контекста характер, и реализуется преимущественно через взаимодействия с ключевыми клинико-анамнестическими параметрами пациента.

7. Выводы

В ходе выполнения выпускной квалификационной работы были решены поставленные задачи, достигнута ключевая цель и проведено обобщение полученных результатов.

Гипотеза: модели машинного обучения обладают не меньшей прогностической ценностью при стратификации рисков кардиохирургических вмешательств в сравнении с традиционными методами, основанными на логистической регрессии, и демонстрируют показатель ROC-AUC не менее 0,7.

На основании результатов исследования можно сделать вывод, что гипотеза подтверждена. Применение нелинейных ансамблевых алгоритмов машинного обучения (Random Forest, LightGBM, CatBoost, XGBoost) позволяет достичь прироста качества прогнозирования госпитальной летальности по сравнению с традиционными медицинскими шкалами (EuroSCORE II). Модель на основе алгоритма Random Forest продемонстрировала наилучшую дискриминационную способность, достигнув показателя площади под ROC-кривой 0.84 на тестовой выборке при сохранении высокой стабильности. Дельта между обучением и тестом составила всего 0.0686, что указывает на превосходную устойчивость ансамбля к шуму в медицинских данных. Индекс Брайера = 0.1245, свидетельствует о хорошей калибровке индивидуального прогноза и надежности выдаваемых процентов риска для конкретного пациента.

8. Перспективы и рекомендации

На основе проведенного комплекса исследований, сравнительного анализа шести прогностических моделей и расчета их консенсус-важности сформулированы рекомендации по прикладному использованию результатов в клинической практике кардиохирургических стационаров:

1. Дифференцированный подход к выбору моделей под клинические задачи:

- Клинические решающие правила (Рекомендательный стек): в качестве ядра систем поддержки принятия врачебных решений для прецизионной оценки госпитальной летальности рекомендуется использовать ПМ IV (Random Forest). Модель продемонстрировала наилучшую предсказательную силу на независимом тесте (ROC-AUC = 0.8494) при высокой стабильности архитектуры ($\Delta = 0.0686$).

- Скрининг-системы быстрого реагирования: для задач первичного экспресс-мониторинга и выделения максимального пула пациентов высокого риска рекомендуется интеграция алгоритма ПМ I (Logistic Regression) с фиксированным порогом отсечения 0.498. Обладая абсолютной устойчивостью ($\Delta = 0.0314$) и высокой чувствительностью (Recall = 0.9091), данная модель минимизирует риск пропуска критического пациента на этапе дооперационного планирования.

2. Оптимизация карт предоперационного обследования:

При сборе анамнеза и формировании электронных медицинских карт (ЭМК) первоочередной фокус должен быть смещен на четыре доминантных фактора: «Объем планируемого вмешательства» (17.311%), «Класс стенокардии» (13.862%), «Функциональный класс по NYHA» (12.905%), «Легочная гипертензия» (10.570%). Данные параметры должны иметь статус обязательных полей для заполнения, так как они аккумулируют около 55% совокупной предсказательной силы.

3. Ограничения на применение ядерных методов:

Не рекомендуется изолированное использование моделей класса ПМ VI (SVM) в практических целях без жестких процедур регуляризации и расширения выборки, ввиду их подтвержденной склонности к критическому переобучению ($\Delta = 0.1454$).

Результаты валидны для прогностической оценки пациентов взрослого возраста, направленных на плановые и экстренные вмешательства в рамках сердечно-сосудистой хирургии (включая коронарное шунтирование, клапанную коррекцию и сочетанные операции). Экстраполяция моделей на детскую кардиохирургию (врожденные пороки сердца) неправомерна без полной переинициализации признакового пространства.

Стабильность моделей (особенно бустинговых архитектур ПМ II, III, V) гарантирована при сохранении структуры распределения признаков, характерной для обучающей выборки. При переходе на клинические протоколы других регионов или стран требуется обязательная калибровка порогов отсечения (Threshold).

В качестве векторов развития текущего исследования для академического сообщества и будущих разработок предлагаются следующие направления:

1. Тестирование альтернативных дизайнов и методик:

- Преодоление эффекта нелинейного шума для возраста и пола: Выявленный факт расхождения знаков и весов для демографических признаков между линейной моделью (ПМ I) и нелинейными ансамблями (LGBM, SVM) требует проведения направленного анализа взаимодействий (Interaction Effects). Перспективным видится внедрение методов GAM (Generalized Additive Models) для экспликации нелинейных зависимостей без усложнения до "черного ящика".

- Гибридизация и стекинг: Логичным шагом развития является разработка гетерогенного ансамбля (стекинга), где мета-моделью выступит

абсолютно устойчивая логистическая регрессия (ПМ), а базовыми алгоритмами — высокоточные древесные модели (ПМ IV и ПМ III). Это позволит математически объединить высокий Recall с высоким качеством ранжирования.

2. Открытые вопросы и новые источники данных:

- Динамический эмбединг клинических трендов: Текущие модели оперируют статическим предоперационным срезом данных. Открытым остается вопрос включения во временной контур предсказания интраоперационных характеристик (время искусственного кровообращения, время пережатия аорты), послеоперационных данных (глюкоза, креатинин) в режиме реального времени.

- Повышение устойчивости ПМ II (CatBoost): Необходим поиск оптимальных стратегий регуляризации (например, жесткое ограничение глубины деревьев и варьирование параметра L2-регуляризации) для снижения переобучения.

9. Заключение

В ходе выполненного исследования внесен вклад в решение актуальной научно-практической проблемы — разработана система прогностических моделей для персонализированной стратификации риска развития неблагоприятных исходов у пациентов кардиохирургического профиля. Осуществлена комплексная оценка шести архитектур машинного обучения на основе критериев предсказательной силы ROC-AUC и устойчивости к переобучению ($\Delta = \text{ROC-AUC}_{\text{Train}} - \text{ROC-AUC}_{\text{Test}}$). Оптимизация порогов отсечения (*Threshold*) проводилась с акцентом на максимизацию полноты охвата пациентов высокого риска, что является критически важным в кардиохирургии. По результатам кросс-валидации и изолированного тестирования сформировано следующее видение моделей:

1. Оптимальный баланс точности и обобщающей способности:

ПМ IV (Random Forest): Признана наиболее эффективной моделью для клинического внедрения. Алгоритм показал наивысшую точность ранжирования на тесте ($\text{ROC-AUC}_{\text{Test}} = 0.8494$) при сохранении высокой стабильности. Дельта между обучением и тестом составила всего 0.0686, что указывает на превосходную устойчивость ансамбля к шуму в медицинских данных. Индекс Брайера = 0.1245, свидетельствует о хорошей калибровке индивидуального прогноза и надежности выдаваемых процентов риска для конкретного пациента.

ПМ I (Logistic Regression): продемонстрировала абсолютную устойчивость к переобучению с минимальной дельтой $\Delta = 0.0314$ ($\text{ROC-AUC}_{\text{Train}} = 0.8522$, $\text{ROC-AUC}_{\text{Test}} = 0.8208$). Она остается надежной скрининг-системой «первого контакта»: при пороге 0.498 она обеспечивает отличную чувствительность $\text{Recall} = 0.9091$, гарантируя выявление максимального числа угрожаемых пациентов. Зафиксирован неудовлетворительный индекс Брайера = 0.2358, близкий к порогу случайного угадывания 0.25), что указывает на

системное завышение вероятностей (гипердиагностику) ради минимизации пропуска критических пациентов.

2. Модели с удовлетворительной стабильностью:

Алгоритмы градиентного бустинга ПМ III (LightGBM) и ПМ V (XGBoost) показали сопоставимые высокие результаты на тесте (ROC-AUC 0.8429 и 0.8325 соответственно). Обладая удовлетворительной устойчивостью ($\Delta=0.07$), эти модели подтвердили свою способность извлекать сложные нелинейные зависимости из признаков, однако требуют жесткого контроля гиперпараметров регуляризации при переносе на новые выборки. При этом LightGBM продемонстрировал наилучшую калибровку вероятностей среди всех исследованных моделей (индекс Брайера = 0.1202).

3. Группа высокого риска (Склонность к переобучению):

- ПМ II (CatBoost): несмотря на то, что алгоритм показал лучший на тесте баланс точности (Precision = 0.3810, F1-score = 0.5000), он продемонстрировал явную склонность к переобучению ($\Delta = 0.1181$). Модель излишне подстраивается под специфику обучающей выборки (ROC-AUC_{Train} = 0.9362).

- ПМ VI (SVM): Метод опорных векторов показал выраженное переобучение. Имея высочайшее качество на тренировочном наборе (ROC-AUC_{Train} = 0.9739), на валидации и тесте модель резко теряет точность, демонстрируя наибольшее падение метрики ($\Delta=0.1454$). Использование нелинейных ядерных пространств в условиях ограниченной медицинской выборки приводит к потере генерализации, что делает ПМ VI нерекомендуемой для изолированного использования без агрессивных методов регуляризации.

Ядром прогностической системы выступают четыре признака, суммарно аккумулирующие около 55% всей предсказательной силы моделей: «Объем операции» (17.311%), «Класс стенокардии» (13.862%), «Функциональный класс NYHA» (12.905%), «Легочная гипертензия» (10.570%). «Возраст»

(6.644%) и «Пол» (6.346%) вносят умеренный вклад и нелинейно взаимодействуют с другими соматическими факторами. Остальные параметры характеризует невысокий изолированный процент важности в ансамблях, что по-видимому указывает на то, что их влияние на неблагоприятный исход реализуется синергетически — в комбинации с признаками верни позиций.

Таким образом, можно заключить что, гипотеза исследования «модели машинного обучения обладают не меньшей прогностической ценностью при стратификации рисков кардиохирургических вмешательств в сравнении с традиционными методами, основанными на логистической регрессии, и демонстрируют показатель ROC-AUC не менее 0,7» подтверждена.

Список литературы

1. Казанцев, А. Н. Стратификация риска развития послеоперационных осложнений в сердечно-сосудистой хирургии / А. Н. Казанцев, К. П. Черных, М. А. Чернявский, Н. Э. Заркуа, И. Х. Шукуров, Р. Ю. Лидер, К. Г. Кубачев, Г. Ш. Багдавадзе, Е. Ю. Калинин, Т. Е. Зайцева, А. Е. Чикин, Ю. П. Линец // Российский медицинский журнал. – 2020. – Т. 26, № 6. – С. 341-350. – DOI: <http://doi.org/10.17816/0869-2106-2020-26-6-341-350>.
2. Abbasi, A. Interpretable machine learning-based predictive modeling of patient outcomes following cardiac surgery / A. Abbasi, C. Li, M. Dekle, C. A. Bermudez, D. Brodie, F. W. Sellke, N. R. Sodha, C. E. Ventetuolo, C. Eickhoff // J Thorac Cardiovasc Surg. – 2025. – Vol. 169, № 1. – P. 114-123.e28. – DOI: 10.1016/j.jtcvs.2023.11.034. – PMID: 38040328. – PMCID: PMC11133766.
3. Ad, N. Comparison of EuroSCORE II, Original EuroSCORE, and The Society of Thoracic Surgeons Risk Score in Cardiac Surgery Patients / N. Ad, S. D. Holmes, J. Patel, G. Pritchard, D. J. Shuman, L. Halpin // Ann Thorac Surg. – 2016. – Vol. 102, № 2. – P. 573-579. – DOI: 10.1016/j.athoracsur.2016.01.105. – PMID: 27112651.
4. Allyn, J. A Comparison of a Machine Learning Model with EuroSCORE II in Predicting Mortality after Elective Cardiac Surgery: A Decision Curve Analysis / J. Allyn, N. Allou, P. Augustin, I. Philip, O. Martinet, M. Belghiti, S. Provenchere, P. Montravers, C. Ferdynus // PLoS One. – 2017. – Vol. 12, № 1. – P. e0169772. – DOI: 10.1371/journal.pone.0169772. – PMID: 28060903. – PMCID: PMC5218502.
5. Allou, N. Clinical utility of a deep-learning mortality prediction model for cardiac surgery decision making / N. Allou, J. Allyn, S. Provenchere, B. Delmas, E. Braunberger, M. Oliver, J. L. De Brux, C. Ferdynus ; EpiCard investigators // J Thorac Cardiovasc Surg. – 2023. – Vol. 166, № 6. – P. e567-e578. – DOI: 10.1016/j.jtcvs.2023.01.022. – PMID: 36858843.

6. Benedetto, U. Can machine learning improve mortality prediction following cardiac surgery? / U. Benedetto, S. Sinha, M. Lyon, A. Dimagli, T. R. Gaunt, G. Angelini, J. Sterne // *Eur J Cardiothorac Surg.* – 2020. – Vol. 58, № 6. – P. 1130-1136. – DOI: 10.1093/ejcts/ezaa229. – PMID: 32810233.
7. Benedetto, U. Machine learning improves mortality risk prediction after cardiac surgery: Systematic review and meta-analysis / U. Benedetto, A. Dimagli, S. Sinha, L. Cocomello, B. Gibbison, M. Caputo, T. Gaunt, M. Lyon, C. Holmes, G. D. Angelini // *J Thorac Cardiovasc Surg.* – 2022. – Vol. 163, № 6. – P. 2075-2087.e9. – DOI: 10.1016/j.jtcvs.2020.07.105. – PMID: 32900480.
8. Bodenhofer, U. Machine learning-based risk profile classification of patients undergoing elective heart valve surgery / U. Bodenhofer, B. Haslinger-Eisterer, A. Minichmayer, G. Hermanutz, J. Meier // *Eur J Cardiothorac Surg.* – 2021. – Vol. 60, № 6. – P. 1378-1385. – DOI: 10.1093/ejcts/ezab219. – PMID: 34050368.
9. Bustamante-Munguira, J. A New Surgical Site Infection Risk Score: Infection Risk Index in Cardiac Surgery / J. Bustamante-Munguira, F. Herrera-Gómez, M. Ruiz-Álvarez, A. Figuerola-Tejerina, A. Hernández-Aceituno // *J Clin Med.* – 2019. – Vol. 8, № 4. – DOI: 10.3390/jcm8040480. – PMID: 30970636. – PMCID: PMC6517895.
10. Darvall, J. N. Heart, home, and frailty: new risk scores and outcomes for cardiac surgery patients / J. N. Darvall, D. A. Story // *Br J Anaesth.* – 2021. – Vol. 126, № 6. – P. 1081-1084. – DOI: 10.1016/j.bja.2021.02.022. – PMID: 33795135.
11. Fernandes, M. P. B. Machine Learning Models with Preoperative Risk Factors and Intraoperative Hypotension Parameters Predict Mortality After Cardiac Surgery / M. P. B. Fernandes, M. Armengol de la Hoz, V. Rangasamy, B. Subramaniam // *J Cardiothorac Vasc Anesth.* – 2021. – Vol. 35, № 3. – P. 857-865. – DOI: 10.1053/j.jvca.2020.07.029. – PMID: 32747203.

12. Hote, M. Cardiac surgery risk scoring systems: In quest for the best / M. Hote // Heart Asia. – 2018. – Vol. 10, № 1. – P. e011017. – DOI: 10.1136/heartasia-2018-011017. – PMID: 29637928. – PMCID: PMC5890060.

13. Kar, P. Mortality prediction in Indian cardiac surgery patients: Validation of European System for Cardiac Operative Risk Evaluation II / P. Kar, K. Geeta, R. Gopinath, P. Durga // Indian J Anaesth. – 2017. – Vol. 61, № 2. – P. 157-162. – DOI: 10.4103/ija.IJA_522_16. – PMID: 28250485. – PMCID: PMC5330073.

14. Kilic, A. Predictive Utility of a Machine Learning Algorithm in Estimating Mortality Risk in Cardiac Surgery / A. Kilic, A. Goyal, J. K. Miller, E. Gjekmarkaj, W. L. Tam, T. G. Gleason, I. Sultan, A. Dubrawksi // Ann Thorac Surg. – 2020. – Vol. 109, № 6. – P. 1811-1819. – DOI: 10.1016/j.athoracsur.2019.09.049. – PMID: 31706872.

15. Leivaditis, V. Artificial Intelligence in Cardiac Surgery: Transforming Outcomes and Shaping the Future / V. Leivaditis, E. Beltsios, A. Papatriantafyllou, K. Grapatsas, F. Mulita, N. Kontodimopoulos, N. G. Baikoussis, L. Tchabashvili, K. Tasios, I. Maroulis, M. Dahm, E. Koletsis // Clin Pract. – 2025. – Vol. 15, № 1. – DOI: 10.3390/clinpract15010017. – PMID: 39851800. – PMCID: PMC11763739.

16. Lin, H. A Novel Risk Stratification System for Predicting In-Hospital Mortality Following Coronary Artery Bypass Grafting Surgery with Impaired Left Ventricular Ejection Fraction / H. Lin, J. Hou, H. Tang, K. Chen, S. Guo, L. Wang, H. Sun, Z. Zheng, S. Hu // Heart Surg Forum. – 2020. – Vol. 23, № 5. – P. E621-E626. – DOI: 10.1532/hsf.3089. – PMID: 32990579.

17. Miles, T. J. Machine learning in cardiac surgery: a narrative review / T. J. Miles, R. K. Ghanta // J Thorac Dis. – 2024. – Vol. 16, № 4. – P. 2644-2653. – DOI: 10.21037/jtd-23-1659. – PMID: 38738250. – PMCID: PMC11087616.

18. Ong, C. S. Prediction of operative mortality for patients undergoing cardiac surgical procedures without established risk scores / C. S. Ong, E. Reinertsen, H. Sun, P. Moonsamy, N. Mohan, M. Funamoto, T. Kaneko, P. S.

Shekar, S. Schena, J. S. Lawton, D'Alessandro DA, M. B. Westover, A. D. Aguirre, T. M. Sundt // J Thorac Cardiovasc Surg. – 2023. – Vol. 165, № 4. – P. 1449-1459.e15. – DOI: 10.1016/j.jtcvs.2021.09.010. – PMID: 34607725. – PMCID: PMC8918430.

19. Ozeren, K. Frailty Assessment to Improve Risk Stratification in Elderly Patients Undergoing Elective Cardiac Surgery / K. Ozeren, A. C. Topcu, I. Kayacioglu // Braz J Cardiovasc Surg. – 2025. – Vol. 40, № 2. – P. e20230182. – DOI: 10.21470/1678-9741-2023-0182. – PMID: 40101125. – PMCID: PMC11922485.

20. Pathare, P. MELD-score for risk stratification in cardiac surgery / P. Pathare, M. Elbayomi, M. Weyand, C. Griesbach, F. Harig // Heart Vessels. – 2023. – Vol. 38, № 9. – P. 1156-1163. – DOI: 10.1007/s00380-023-02262-9. – PMID: 37004541. – PMCID: PMC10372113.

21. Penny-Dimri, J. C. Machine learning to predict adverse outcomes after cardiac surgery: A systematic review and meta-analysis / J. C. Penny-Dimri, C. Bergmeir, L. Perry, L. Hayes, R. Bellomo, J. A. Smith // J Card Surg. – 2022. – Vol. 37, № 11. – P. 3838-3845. – DOI: 10.1111/jocs.16842. – PMID: 36001761. – PMCID: PMC9804388.

22. Petricevic, M. Bleeding risk stratification in coronary artery surgery: the should-not-bleed score / M. Petricevic, M. Petricevic, M. Pasalic, B. Golubic Cepulic, M. Raos, V. Vasicek, K. Goerlinger, K. Rotim, H. Gasparovic, B. Biocina // J Cardiothorac Surg. – 2021. – Vol. 16, № 1. – P. 103. – DOI: 10.1186/s13019-021-01473-3. – PMID: 33882969. – PMCID: PMC8059187.

23. Prins, C. Cardiac surgery risk-stratification models / C. Prins, I. de Villiers Jonker, L. Botes, F. E. Smit // Cardiovasc J Afr. – 2012. – Vol. 23, № 3. – P. 160-164. – DOI: 10.5830/CVJA-2011-047. – PMID: 22555640. – PMCID: PMC3721858.

24. Ranucci, M. In search of the ideal risk-scoring system for very high-risk cardiac surgical patients: a two-stage approach / M. Ranucci, U. Di Dedda, S.

Castelvecchio, M. T. La Rovere, L. Menicanti ; Surgical and Clinical Outcome Research (SCORE) Group // J Cardiothorac Surg. – 2016. – Vol. 11. – P. 13. – DOI: 10.1186/s13019-016-0405-3. – PMID: 26782077. – PMCID: PMC4717657.

25. Ranucci, M. The ACEF II Risk Score for cardiac surgery: updated but still parsimonious / M. Ranucci, V. Pistuddi, S. Scolletta, C. de Vincentiis, L. Menicanti // Eur Heart J. – 2018. – Vol. 39, № 23. – P. 2183-2189. – DOI: 10.1093/eurheartj/ehx228. – PMID: 28498904.

26. Saxena, A. The Benefits and Pitfalls of the Use of Risk Stratification Tools in Cardiac Surgery / A. Saxena, V. Dhurandhar, P. G. Bannon, A. E. Newcomb // Heart Lung Circ. – 2016. – Vol. 25, № 4. – P. 314-318. – DOI: 10.1016/j.hlc.2015.12.094. – PMID: 26857968.

27. Sinha, S. A machine learning algorithm-based risk prediction score for in-hospital/30-day mortality after adult cardiac surgery / S. Sinha, T. Dong, A. Dimagli, A. Judge, G. D. Angelini // Eur J Cardiothorac Surg. – 2024. – Vol. 66, № 4. – DOI: 10.1093/ejcts/ezae368. – PMID: 39374541. – PMCID: PMC11522872.

28. Sinha, S. Comparison of machine learning techniques in prediction of mortality following cardiac surgery: analysis of over 220 000 patients from a large national database / S. Sinha, T. Dong, A. Dimagli, H. A. Vohra, C. Holmes, U. Benedetto, G. D. Angelini // Eur J Cardiothorac Surg. – 2023. – Vol. 63, № 6. – DOI: 10.1093/ejcts/ezad183. – PMID: 37154705. – PMCID: PMC10275911.

29. Sinha, S. Systematic review and meta-analysis of mortality risk prediction models in adult cardiac surgery / S. Sinha, A. Dimagli, L. Dixon, M. Gaudino, M. Caputo, H. A. Vohra, G. Angelini, U. Benedetto // Interact Cardiovasc Thorac Surg. – 2021. – Vol. 33, № 5. – P. 673-686. – DOI: 10.1093/icvts/ivab151. – PMID: 34041539. – PMCID: PMC8557799.

30. Sullivan, P. G. Meta-Analysis Comparing Established Risk Prediction Models (EuroSCORE II, STS Score, and ACEF Score) for Perioperative Mortality During Cardiac Surgery / P. G. Sullivan, J. D. Wallach, J. P. Ioannidis // Am J

Cardiol. – 2016. – Vol. 118, № 10. – P. 1574-1582. – DOI: 10.1016/j.amjcard.2016.08.024. – PMID: 27687052.

31. Zeng J., Zhang D., Lin S., Su X., Wang P., Zhao Y., Zheng Z. Comparative analysis of machine learning vs. traditional modeling approaches for predicting in-hospital mortality after cardiac surgery: temporal and spatial external validation based on a nationwide cardiac surgery registry // Eur Heart J Qual Care Clin Outcomes. 2024. Vol. 10, No. 2. P. 121-131. doi: 10.1093/ehjqcco/qcad028. PMID: 37218710.

Приложение

Листинг 1 — Код прогностических моделей

```
from imblearn.pipeline import Pipeline as ImbPipeline
from imblearn.over_sampling import SMOTE
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from catboost import CatBoostClassifier
from lightgbm import LGBMClassifier
from xgboost import XGBClassifier
from sklearn.svm import SVC
from sklearn.model_selection import GridSearchCV,
StratifiedKFold
import numpy as np
import pandas as pd
import warnings

# Игнорирование некритичных предупреждений библиотек для чистоты
вывода протокола вычислений
warnings.filterwarnings('ignore')

def get_imb_pipeline(clf, scale=False):
    """
    Фабрика сквозных вычислительных конвейеров (Pipelines).
    Инкапсулирует предобработку и обучение внутри единого
    изолированного контейнера.
    Это гарантирует проведение оверсэмплинга (SMOTE)
    ИСКЛЮЧИТЕЛЬНО на обучающих фолдах,
    полностью исключая утечку данных (data leakage) во временные
    валидационные подмножества.
    """
    steps = []
    if scale:
        # Стандартизация признакового пространства: Z-
        масштабирование (mean=0, std=1)
        # Необходима для метрических (SVM) и линейных (LR)
        алгоритмов
        steps.append(('scaler', StandardScaler()))

    # Синтетический оверсэмплинг (SMOTE) для компенсации
    дисбаланса клинических классов.
    # Фиксация random_state обеспечивает строгую
    воспроизводимость результатов эксперимента.
    steps.append(('smote', SMOTE(random_state=42)))
    steps.append(('model', clf))
    return ImbPipeline(steps)

# Конфигуратор многомодельного эксперимента и сеток поиска
(Hyperparameter Grid)
models_config = {
```

```

    'ПМ I (LR)': {
        'model': LogisticRegression(max_iter=3000,
solver='liblinear', random_state=42),
        'params': {
            # Параметр обратной силы регуляризации. Фокус на
            # малых значениях (жесткий штраф)
            # для подавления мультиколлинеарности и стабилизации
            # весов признаков
            'model__C': [0.005, 0.01, 0.05, 0.1, 0.5, 1.0],
            # Исследование структурных различий: L1 (Lasso –
            # разреживание) и L2 (Ridge – сжатие)
            'model__penalty': ['l1', 'l2'],
            # Оптимизация локального радиуса генерации
            # синтетических объектов миноритарного класса
            'smote__k_neighbors': [2, 3, 5]
        },
        'scale': True # Линейные модели критичны к масштабу осей
        # признакового пространства
    },

    'ПМ III (LGBM)': {
        'model': LGBMClassifier(random_state=42, verbose=-1),
        'params': {
            # Ограничение объема ансамбля для предотвращения
            # переобучения на зашумленной выборке
            'model__n_estimators': [100, 150, 200],
            # Темп адаптации (learning rate), демпфирующий вклад
            # каждого последующего дерева
            'model__learning_rate': [0.01, 0.03],
            # Резкое ограничение вертикального ветвления
            # (максимум 15 листьев вместо стандартных 31)
            'model__num_leaves': [7, 15],
            # Минимально допустимая мощность подмножества
            # объектов в терминальном листе (не менее 15-30 пациентов)
            'model__min_child_samples': [15, 20, 30],
            # Регуляризация типа подпространств (стохастический
            # выбор 60-80% признаков на сплит)
            'model__colsample_bytree': [0.6, 0.8],
            # Мощный Ridge-регуляризатор (L2-штраф) для
            # стабилизации листовых весов
            'model__reg_lambda': [5, 10, 20, 50],
            'smote__k_neighbors': [3, 5]
        },
        'scale': False # Деревья решений инвариантны к
        # монотонным преобразованиям шкал
    },

    'ПМ V (XGBoost)': {
        'model': XGBClassifier(eval_metric='logloss',
random_state=42),
        'params': {

```



```

        'model__n_estimators': [100, 150, 200],
        'model__learning_rate': [0.01, 0.03],
        # Жесткое ограничение максимальной глубины
(max_depth <= 4) для минимизации дисперсии модели
        'model__max_depth': [2, 3, 4],
        # Параметр L2-регуляризации структурных весов модели
        'model__lambda': [5, 10, 20, 50],
        # Строковый бэггинг: доля объектов выборки,
используемая для обучения конкретного дерева
        'model__subsample': [0.7, 0.8],
        # Колоночный бэггинг: ограничение подмножества
признаков для декорреляции базовых алгоритмов
        'model__colsample_bytree': [0.6, 0.8],
        'smote__k_neighbors': [3, 5]
    },
    'scale': False
},

    'ПМ II (CatBoost)': {
        'model': CatBoostClassifier(verbose=0, random_state=42,
early_stopping_rounds=40),
        'params': {
            # Ограничение глубины регулярных симметричных
деревьев (обливиатных деревьев)
            'model__depth': [3, 4, 5],
            # Экстремально завышенные коэффициенты L2-
регуляризации на листьях против подгонки под шум
            'model__l2_leaf_reg': [10, 20, 40, 60],
            # Сниженный верхний порог итераций (балансируется
механизмом early_stopping_rounds)
            'model__iterations': [200, 350],
            'smote__k_neighbors': [3, 5]
        },
        'scale': False
    },

    'ПМ IV (RF)': {
        'model': RandomForestClassifier(random_state=42),
        'params': {
            # Количество независимых деревьев в ансамбле
бэггинга
            'model__n_estimators': [150, 300],
            # Ограничение глубины ветвления для исключения
чистой гипердифференциации выборки
            'model__max_depth': [3, 5, 7],
            # Минимальный объем клинических прецедентов,
фиксируемый в терминальном узле
            'model__min_samples_leaf': [4, 6, 8, 12],
            # Ограничение числа предикатов при поиске
оптимального сплита (классический sqrt и 50%)
            'model__max_features': ['sqrt', 0.5],

```

```

        'smote__k_neighbors': [3, 5]
    },
    'scale': False
},

'ММ VI (SVM)': {
    'model': SVC(probability=True, random_state=42),
    'params': {
        # Штраф за нарушение зазора между классами.
        # Исклучены высокие значения C (C > 2.0),
        # приводящие к чрезмерному искривлению разделяющей
        # гиперплоскости под выбросы
        'model__C': [0.05, 0.1, 0.5, 1.0, 2.0],
        # Параметр ширины окна радиальной базисной функции
        # (RBF), управляющий локальностью ядра
        'model__gamma': ['scale', 0.005, 0.01],
        # Использование нелинейного ядра Радиально-Базисной
        # Функции (RBF)
        'model__kernel': ['rbf'],
        'smote__k_neighbors': [3, 5]
    },
    'scale': True # Метод опорных векторов критически
    # чувствителен к метрике расстояния
}
}

print("--- СТАРТ УЛУЧШЕННОГО ПРОЦЕССА ОБУЧЕНИЯ (N~243) ---")

# Валидационная стратегия: 5-кратная стратифицированная кросс-
# валидация.
# Сохраняет баланс долей целевых исходов (осложнений) в каждом
# вычислительном фолде.
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
final_pms = {}

for name, config in models_config.items():
    print(f"⚙ Подбираем параметры для {name}...")

    # Генерация сквозного пайплайна под конкретную архитектуру
    # классификатора
    pipeline = get_imb_pipeline(config['model'],
                                scale=config['scale'])

    # Решетчатый поиск оптимального вектора параметров
    # (GridSearch).
    # scoring='roc_auc' — оптимизация площади под ROC-кривой как
    # инварианта к сдвигу порога.
    # n_jobs=-1 — распараллеливание независимых вычислительных
    # потоков на все доступные ядра CPU.
    grid = GridSearchCV(pipeline, config['params'], cv=skf,
                        scoring='roc_auc', n_jobs=-1, verbose=1)

```

```
# Экспериментальное обучение и кросс-валидация на
изолированной обучающей выборке
grid.fit(X_train, y_train)

# Экстракция наилучшей аппроксимирующей модели (лучшего
оценщика)
final_pms[name] = grid.best_estimator_

print(f"✅ {name} готова!")
print(f"Лучшие параметры: {grid.best_params_}\n" + "-"*40)
```